AI Certificate for Everyone

더에이아이랩(주)
AICE공인교육기관

AICE Associate 특강

- 강좌 소개
- AI 구현 프로세스의 이해
- Python 데이터 분석 및 모델링

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

목차

❖ 강좌 소개

- AICE 시험이란?
- 학습 목표
- 인공지능 개념

❖ AI 구현 프로세스의 이해

- 문제정의
- 데이터 수집
- 데이터 분석
- 데이터 전처리
- AI 모델링

❖ Python 데이터 분석 및 모델링

- 파이썬 소개
- AIDU를 이용한 실습 환경 세팅
- 데이터 분석 라이브러리 소개
- 파이썬 AI 모델링 프로세스

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

강사 소개

AICE 공인강사 조 우 연

bliss@codingx.ai

❖ 학력

석사 : 아주대학교 인공지능학과

학사 (주) : 아주대학교 수학과

학사 (복수) : 아주대학교 컴퓨터공학과

❖ 수상

과기정통부 2025 ICT 우수 강사

SW 인재 페스티벌 기업상

- 과학기술정보통신부 주최, IITP / 소프트웨어중심대학협의회 주관

LINC 3.0 캡스톤디자인 경진대회 장려상

Ajou SOFTCON 개발부문 최우수상

APC 프로그래밍 경시대회 우수상

MIC 코딩대회 장려상

❖ 경력

2024.05 ~ KT AICE 강의

- KT AICE 정기시험 대비 무료/유료 특강 (Associate)
- 강남구청 청년취업아카데미 (BASIC, Associate)
- 20+개 대학 AI 활용능력 워크샵 및 특강 (BASIC, Associate, Pro.)
- 코딩엑스 VOD (BASIC, Associate)

2021.08 ~ 코딩엑스 강사

2019.01 ~ 2023.08 수학 강사

2021.12~2022.02 Crescom, 의료 인공지능 개발

❖ 논문

"Differentiable Cardinality Constraints for Partial Index Tracking", *AAAI 2025 (oral)*

"지역 통합 대기 오염 예측을 위한 해석 가능한 딥러닝 모델의 제안과 분석", *The Korean Computer Congress, KCC 2024 (oral)*

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

강좌소개

1) AICE 시험이란?

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

AICE 시험이란?

AICE 핵심

- 인공지능 기술을 제대로 다룰 수 있는지를 검증

해석
인공지능의 재료인 빅데이터를 해석하고 다룰 수 있는가?
→
다양한 데이터에 기반한 문항
기업 데이터, 공공 데이터, Tabular / Image / Text 데이터 등

활용
인공지능 기술을 상황에 맞게 활용 할 수 있는가?
→
실질적인 AI 활용능력 평가
데이터 탐색 > 데이터 분석 > AI 모델링 > AI 모델 평가

해결
현실의 문제를 인공지능으로 해결 할 수 있는가?
→
실사례 기반 문제해결 역량 평가
예시) (교통) 내비게이션 목적지 도착시간 예측, (제조) 선박 수주여부 예측 등

이미지 출처 : AICE 홈페이지 https://aice.study/info/aice

AICE 시험종류

- **PROFESSIONAL** AI/SW 개발자 | 전공자 | 파이썬

  이미지 등 다양한 종류의 데이터를 기반으로 AI 서비스 모델 개발 역량

  문제 해결을 위한 다양한 데이터를 분석/처리 후
  최적의 알고리즘을 적용하여 AI모델링 할 수 있는 능력을 평가

- **ASSOCIATE** 기획/분석 | 준/전공자 | 파이썬

  데이터 분석/처리 및 AI 모델링 통한 비지니스 혁신 역량

  실수에서 가장 많이 쓰는 Tabular 데이터에 대해
  코딩(파이썬) 기반으로 데이터 분석/처리/모델링

- **BASIC** 직책자 | 비전공자 | NO 코딩

  AI 원리, 업무활용 이해 및 결과 해석 역량

  실무에서 가장 많이 쓰이는 Tabular 데이터에 대해
  코딩 없이 Auto ML 기반으로 데이터 분석/모델링

- **JUNIOR** 중고등학생 | 중고등 교사 | NO 코딩

  AI 개념, 용어, 프로세스 등 AI 문해력

  생활 속 AI 적용사례와 데이터를 가지고 코딩 없이 Auto ML 기반으로 데이터 분석/모델링

- **FUTURE** 초등학생 | 초등 교사 | 블록코딩

  AI 구현원리 및 컴퓨팅 사고력

  누구나 쉽고 재미있게 블록코딩 기반으로 AI 핵심 작동원리 이해 및 구현

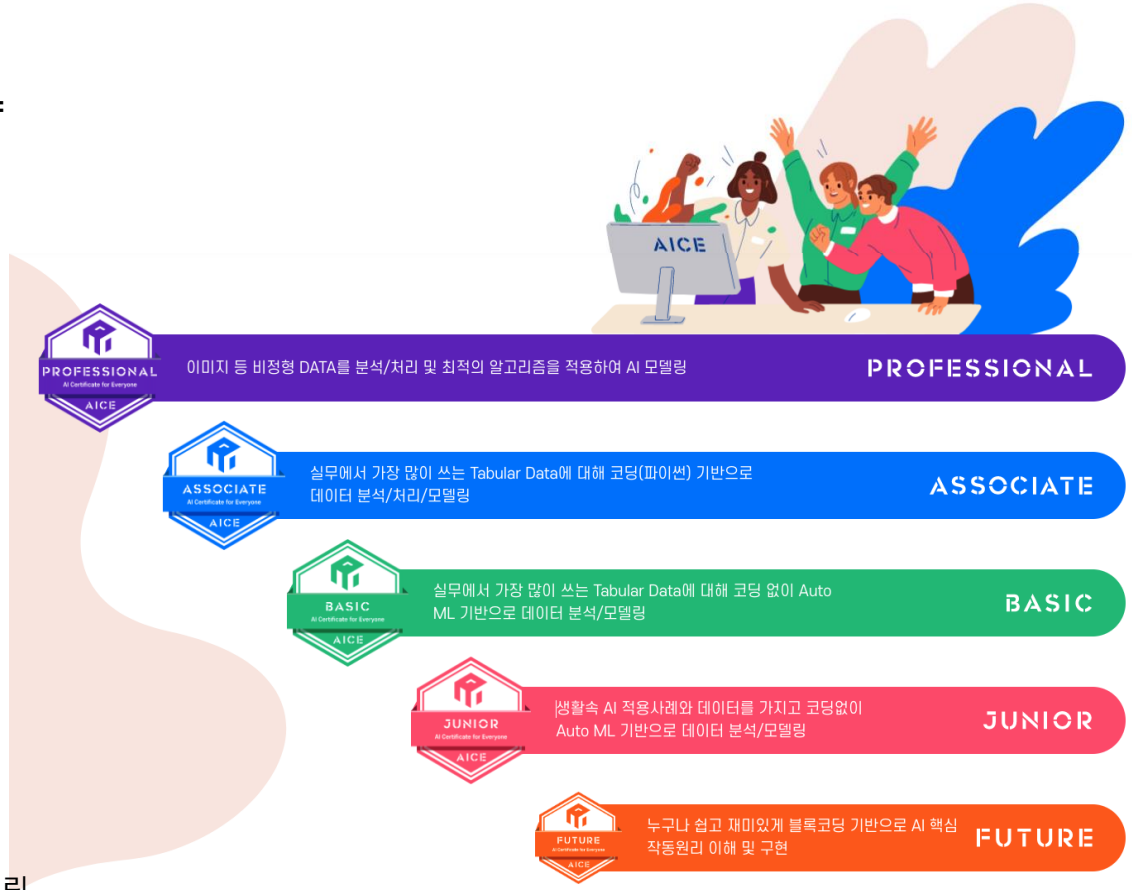

이미지 출처 : AICE 홈페이지 https://aice.study/info/aice

AICE 시험설명

- **ASSOCIATE** 기획/분석 준/전공자 파이썬

데이터 분석/처리 및 AI 모델링 통한 비지니스 혁신 역량

실무에서 가장 많이 쓰는 Tabular 데이터에 대해
코딩(파이썬) 기반으로 데이터 분석/처리/모델링

✓ **출제범위**

탐색적 데이터 분석
→ 라이브러리 설치 / Tabular 데이터 로딩 /
데이터 구성 확인 및 상관분석 / 데이터 시각화

데이터 전처리
→ 결측치 처리 / 인코딩 / x,y 데이터 분리 / 정규 분포화, 표준화

머신러닝 / 딥러닝모델링
→ 라이브러리, 프레임워크 활용하여 예측, 분류 모델 모델링

모델 성능평가
→ 모델 성능평가 및 그래프 출력

✓ **문항 수**

90분 → 14문항

✓ **합격 커트라인**

80점 이상

이미지 출처 : AICE 홈페이지 https://aice.study/info/aice

강좌소개

2) 학습 목표

학습 목표

- 정형데이터(표 데이터)를 이해하고 처리할 수 있으며 데이터와 인공지능 모델을 활용하여 문제를 해결할 수 있다.

- AICE Associate 자격을 취득할 수 있도록 AI 모델링 프로세스를 이해하고, 이에 따라 Python 라이브러리와 오픈소스를 활용해 데이터 분석 및 AI 모델 구현을 할 수 있다.

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

강좌소개

3) 인공지능 개념

인공지능(AI)이란?

<아이언맨> 자비스?

유튜브 알고리즘? chatGPT?

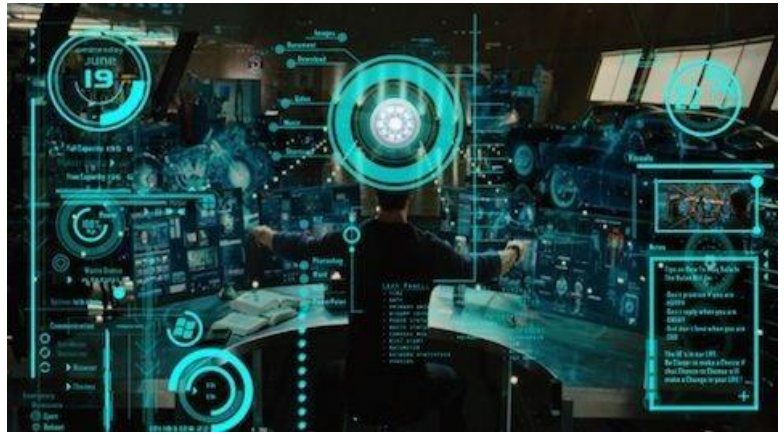

이미지 출처 : https://n.news.naver.com/mnews/article/092/0002027227, https://blog.naver.com/yoon1839/222374772987,

인공지능(AI)이란?

- **업무에 도움**을 주려는 분야

  예) 번역, 챗봇, 내비게이션, 유튜브 알고리즘, 자율주행, ...)

- **새로운 것을 창조**해내는 분야

  예) 작곡, 화가, 음성합성, 흑백사진 복원, ...

이미지 출처 : https://blog.naver.com/tjoeunbu/223105974473, https://blog.naver.com/fureunpyeongchang/223263869319, https://blog.naver.com/puel0122/222013915076

인공지능(AI)이란?

- **업무에 도움**을 주려는 분야

  예) 번역, 챗봇, 내비게이션, 유튜브 알고리즘, 자율주행, ...)

- **새로운 것을 창조**해내는 분야

  예) 작곡, 화가, 음성합성, 흑백사진 복원, ...

→ **인공지능(AI)** : 인간의 지적 능력을 구현하는 모든 기술

→ 즉, **인지, 추론, 학습** 등 전반적인 인간의 사고과정에서 필요한 능력을 모방하는 기술

이미지 출처 : https://blog.naver.com/tjoeunbu/223105974473, https://blog.naver.com/fureunpyeongchang/223263869319, https://blog.naver.com/puel0122/222013915076

인공지능(AI)이란?

인공지능(AI) : 인간의 지적 능력을 구현하는 모든 기술

→ 즉, **인지, 추론, 학습** 등 전반적인 인간의 사고과정에서 필요한 능력을 모방하는 기술

→어떻게 기계를 사람처럼 학습시키지??

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

인공지능(AI)이란?

인공지능(AI) : 인간의 지적 능력을 구현하는 모든 기술

→ 즉, **인지, 추론, 학습** 등 전반적인 인간의 사고과정에서 필요한 능력을 모방하는 기술

→어떻게 기계를 사람처럼 학습시키지??

→Solution : 머신러닝

: 알고리즘을 기반으로 데이터를 스스로 분석/학습하여 판단하거나 예측하는 기술 또는 관련된 연구 분야

→ 딥러닝?

: 머신러닝의 한 분야로, 인간의 뇌(뉴런)을 본떠 구성한 '인공신경망' 알고리즘을 활용하여 정보를 학습하고 처리하는 기술

* 알고리즘 : 연산의 반복을 포함하는 정해진 단계에서 수학적 문제를 해결하는 절차

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

인공지능(AI)이란?

인공지능 – 머신러닝 – 딥러닝 사이의 관계

인공지능
인간의 지적 능력을
구현하는 모든 기술

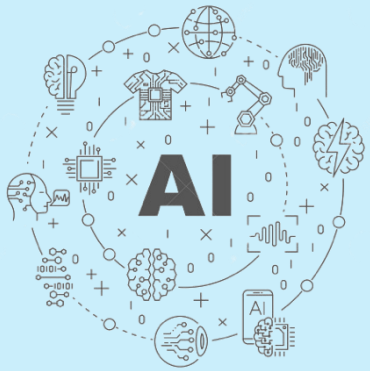

머신러닝
알고리즘을 기반으로
데이터를 스스로
분석 및 학습해
판단하거나 예측하는
기술 또는
관련된 연구 분야

딥러닝
'인공신경망' 알고리즘을
활용해 정보를 학습하고
처리하는 기술

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

머신러닝 (Machine Learning) 개념

< 시험공부 할 때 학습법 >

- **인간**

  최대한 많은 자료를 수집해 보고 외우며, 틀린 문제는 반복적으로 숙지하면서 발생할 수 있는 오답을 최소화

- **AI**

  많은 데이터를 기반으로 문제를 반복해 풀고 오차를 최소화

많은 자료

반복 →

능력 향상

데이터

반복 →

성능 향상

이미지 출처: https://kor.pngtree.com/freepng/pile-of-books_792652.html, https://kr.lovepik.com/image-401180807/students-who-study-hard.html, https://kr.freepik.com/premium-vector/the-words-big-data-surrounded-by-icons_2427856.htm

머신러닝 (Machine Learning) 개념

기존의 전통적인 프로그램

→ 컴퓨터에 필요한 규칙을 컴퓨터가 이해할 수 있는 언어로 사람이 직접 입력(프로그래밍)

머신러닝

→ 경험한 데이터를 통해 스스로 규칙을 생성

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

머신러닝 (Machine Learning) 개념

기존의 전통적인 프로그램

→ 컴퓨터에 필요한 규칙을 컴퓨터가 이해할 수 있는 언어로 사람이 직접 입력(프로그래밍)

머신러닝

→ 경험한 데이터를 통해 스스로 규칙을 생성

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

머신러닝 (Machine Learning) 개념

- **머신러닝 (Machine Learning)**

  컴퓨터가 다양한 머신러닝 학습 모델을 기반으로 제공된 데이터를 이용해 학습을 수행하고, 모델의 성능을 반복적으로 평가하며, 스스로 성능을 향상하는 것

  → **데이터를 잘 설명할 수 있는 하나의 함수를 찾는 것**

  → 사람이 함수를 직접 구현할 필요 없이 입력된 **데이터를 토대로 최적의 모델을 생성**

- **머신러닝 유형**

  1. 지도학습 (Supervised Learning)
  2. 비지도학습 (Unsupervised Learning)
  3. 강화학습 (Reinforcement Learning)

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

AI 학습방법 : 지도학습

1. 지도학습 (Supervised Learning)

문제와 정답(레이블)을 알려주고 학습하는 방법

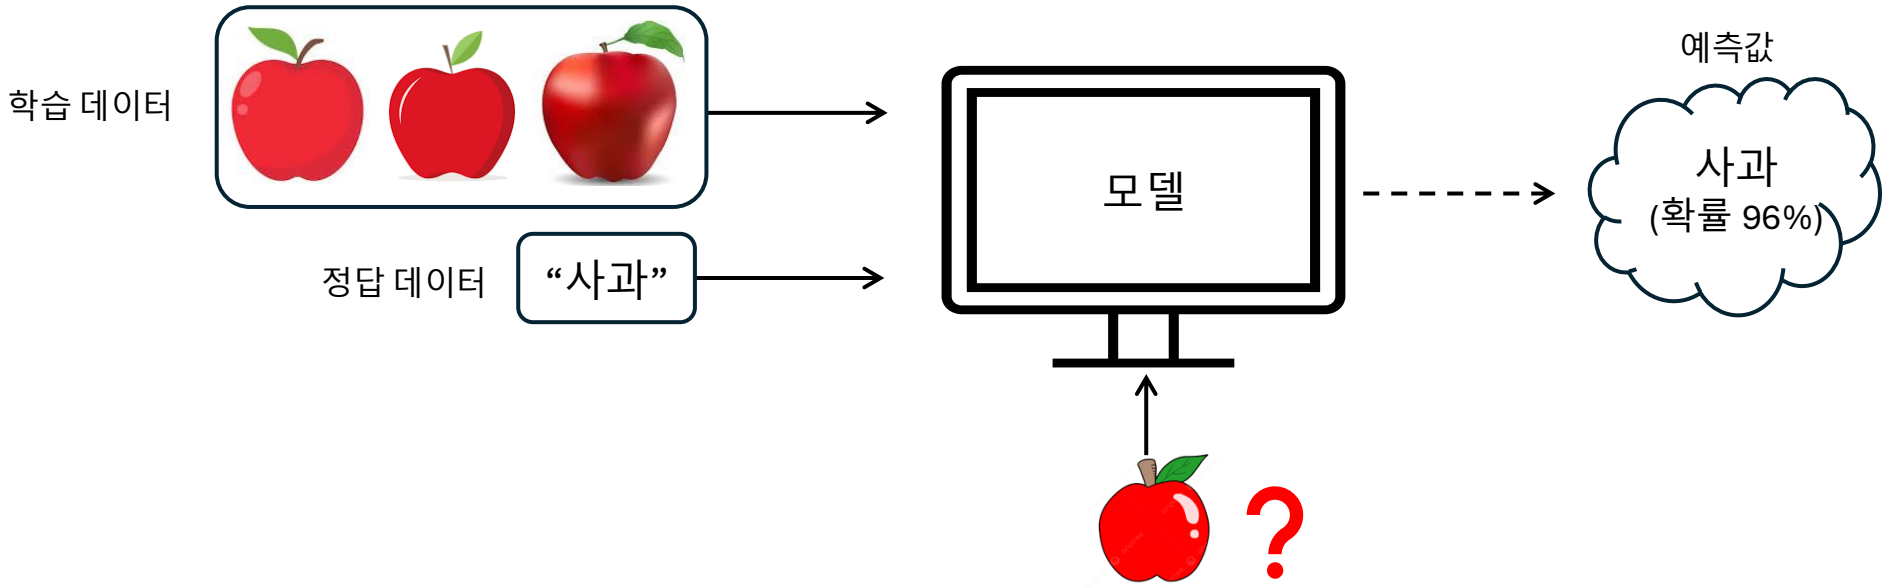

→ 과거에 경험된 데이터로 미래를 예측

→ 양질의 데이터가 많이 제공될수록 더 효율적인 학습 가능

→ 예측하고자 하는 값에 따라 **분류(Classification)** 모델과 **회귀(Regression)** 모델로 다시 구분

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

AI 학습방법 : 지도학습

1. 지도학습 (Supervised Learning)

- **분류(Classification) 모델**

  명확하게 나눠진 범주형(Categorical)인 결과값을 예측하는 모델

  ex) 사과,복숭아,바나나 분류, 개/고양이 분류

- **회귀(Regression) 모델**

  연속적인 수치형으로 이루어진 데이터를 예측하는 모델

  ex) 부동산 가격, 주가, 사람 몸무게로 키 예측

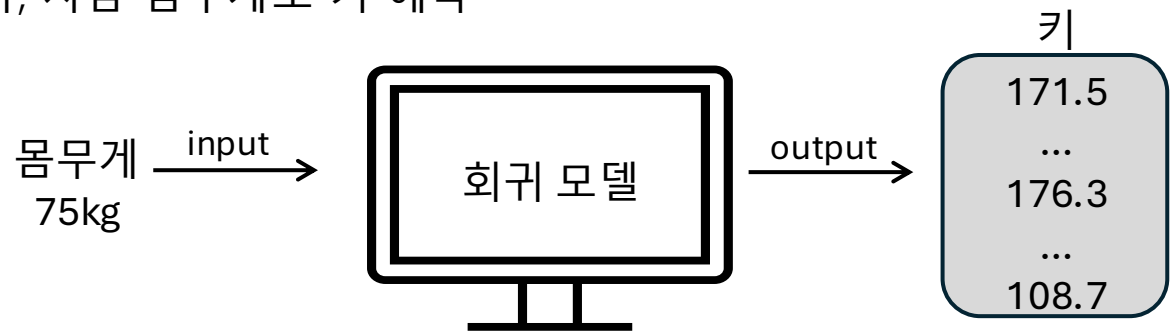

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

AI 학습방법 : 지도학습

분류 / 회귀 모델의 수학적 표현 : 각 모델은 데이터를 가장 잘 대변하는 함수로 표현

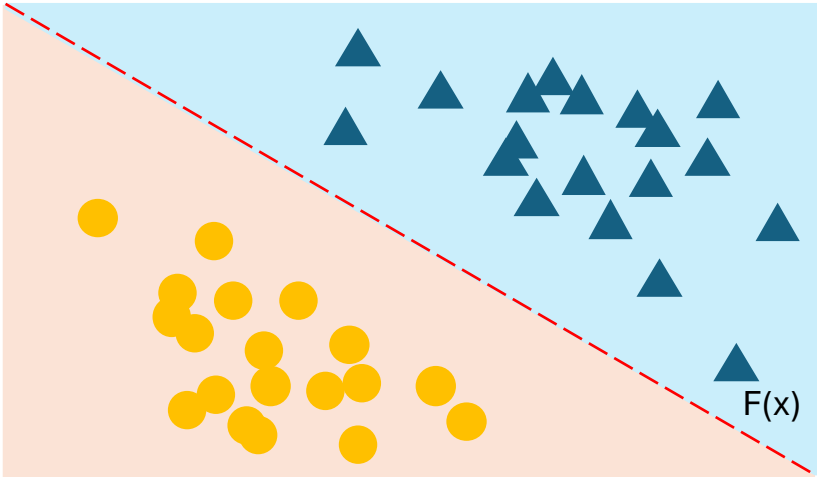

→ **분류(Classification) 모델**

데이터를 구분하는 경계를 나누는 선(함수)

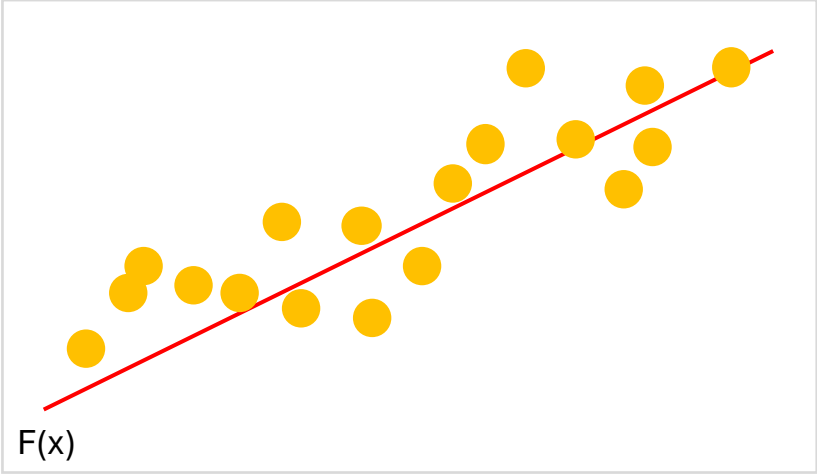

→ **회귀(Regression) 모델**

증가하고 감소하는 데이터의 규칙을 찾고, 오차를 가장 적게 하는 선(함수)

* 결정경계(Decision Boundary) : 분류와 회귀 모델을 기계가 표현하는 함수

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

AI 학습방법 : 지도학습

분류 / 회귀 모델의 수학적 표현 : 각 모델은 데이터를 가장 잘 대변하는 함수로 표현

→ 독립변수(설명변수, feature, x)의 패턴을 학습하여 종속변수(반응변수, 레이블, 타깃변수, y)를 예측하는 함수

과소적합 모델

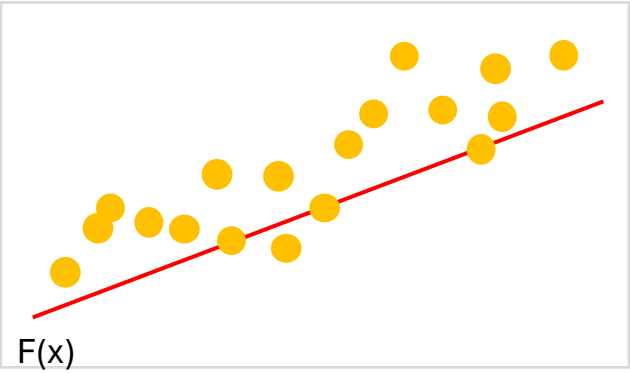

이상적인 모델

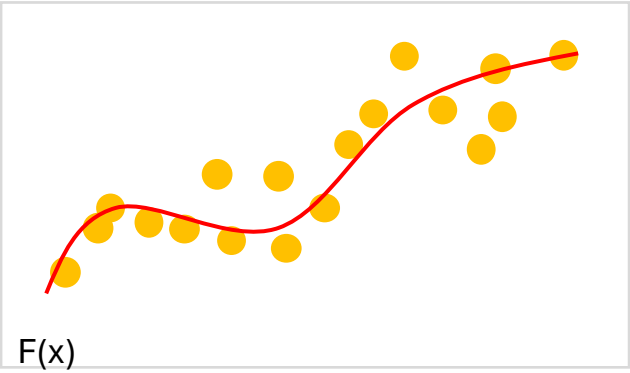

과대적합 모델

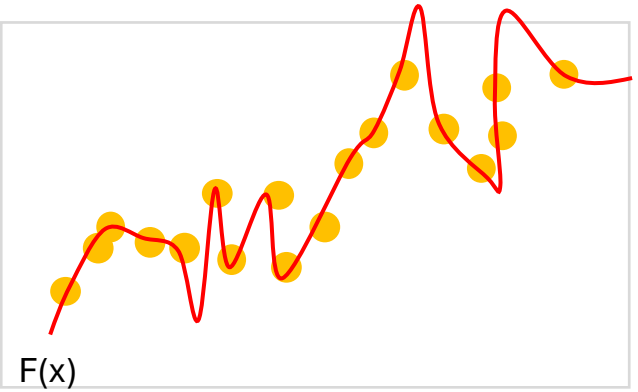

→ 지도학습 모델이 과대적합 되었는지를 확인하는 방법

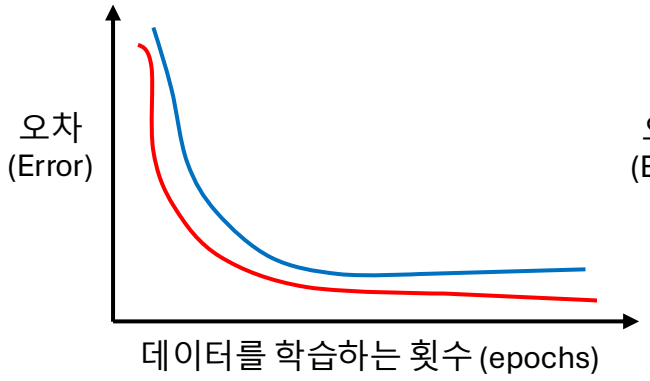

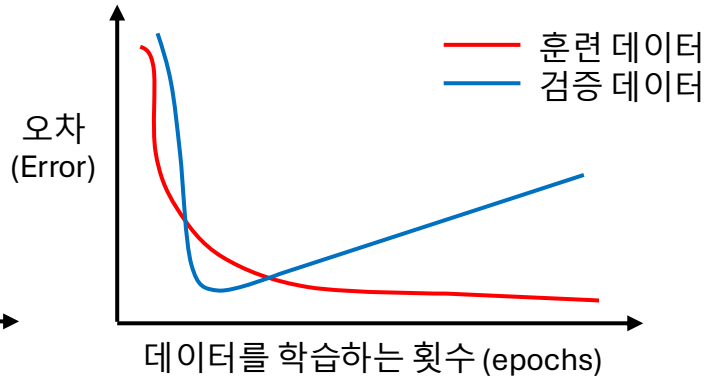

→과대적합이 되면 학습을 진행할수록 훈련 데이터의 오차는 계속 감소하지만 검증 데이터 오차는 감소하다가 어느 순간부터 다시 커짐

→**Early Stopping**
: 검증 데이터 오차가 훈련 데이터 오차보다 너무 커지기 전에 학습을 조기 중단하여 방지

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

AI 학습방법 : 비지도학습

2. 비지도학습 (Unsupervised Learning)

정답(레이블)을 알려주지 않고 문제만 주어서 학습하는 방법

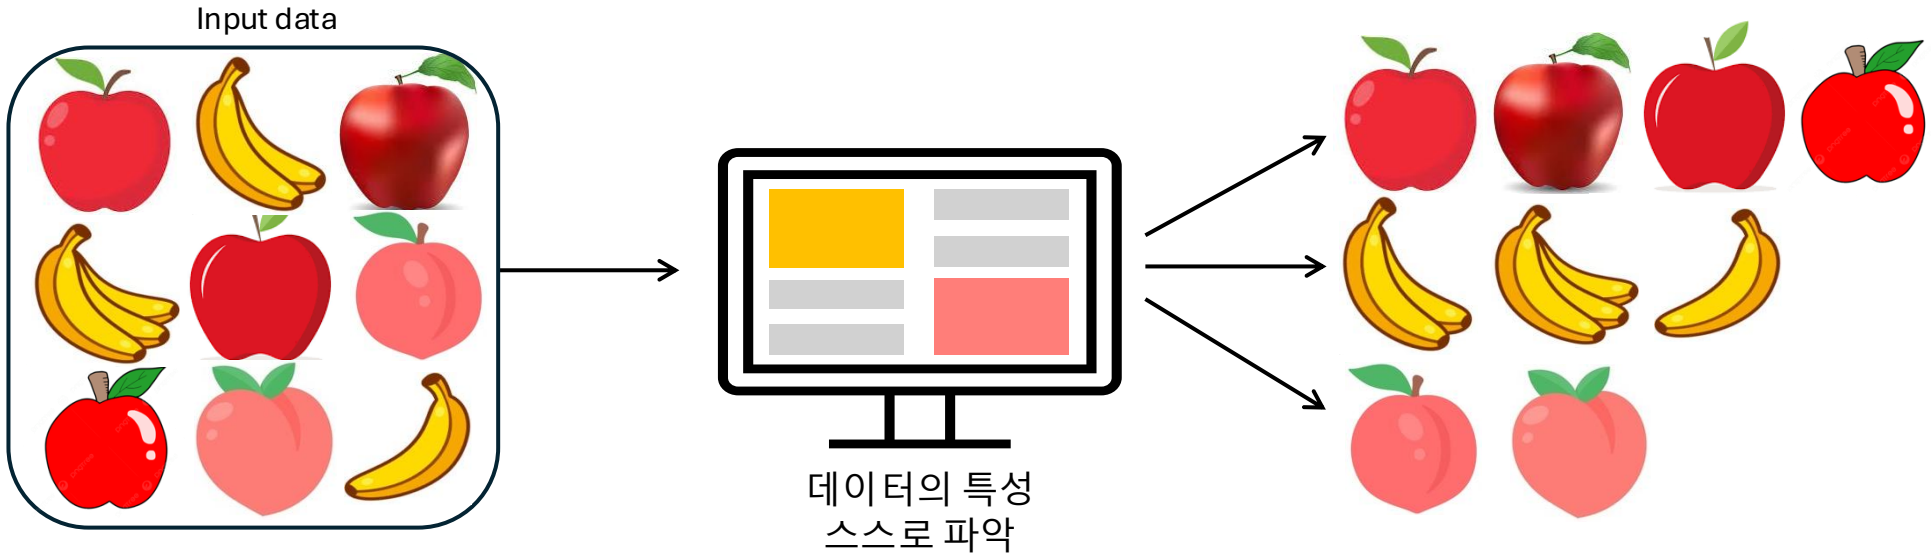

→ 유사한 특성을 가진 데이터끼리 그룹화 진행

ex) 색이 빨간색인지, 노란색인지 / 모양이 동그란지, 길쭉한지 / 잎이 있는지, 없는지

→ 데이터 자체가 가진 특성과 상관관계를 기계가 스스로 학습하여 유사한 데이터끼리 그룹화

→ 이를 군집화(Clustering)라고 함

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

AI 학습방법 : 비지도학습

2. 비지도학습 (Unsupervised Learning)

- k-means 군집화

  k개의 그룹으로 유사한 데이터들의 그룹을 나누는 것

(예시)

입력 데이터

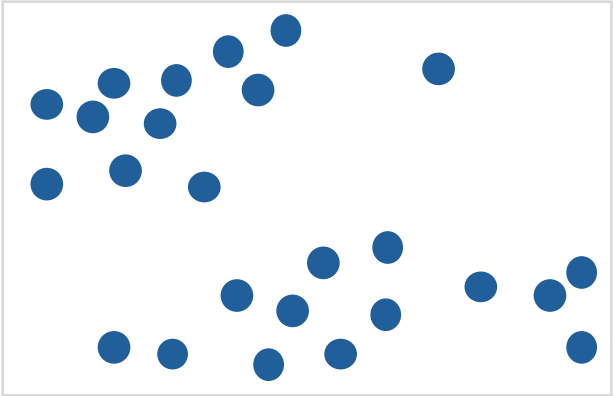

k=2

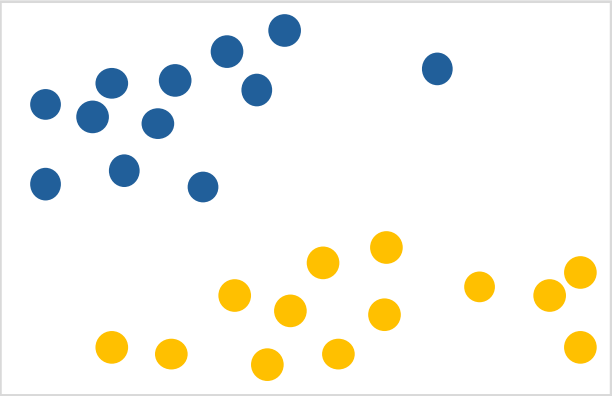

k=4

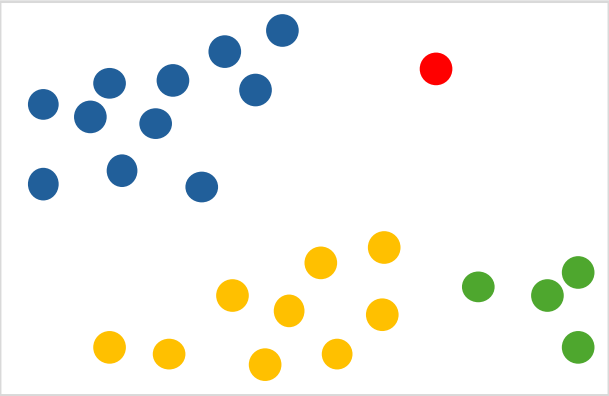

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

딥러닝(Deep Learning) 개념

➢ **딥러닝 (Deep Learning)**

뇌(brain)의 정보처리방식을 모사한 인공신경망과 유사하게 여러 층(Layer)으로 깊이 있기(Deep) 구성하여 학습을 진행하는 머신러닝 알고리즘

[뉴런]

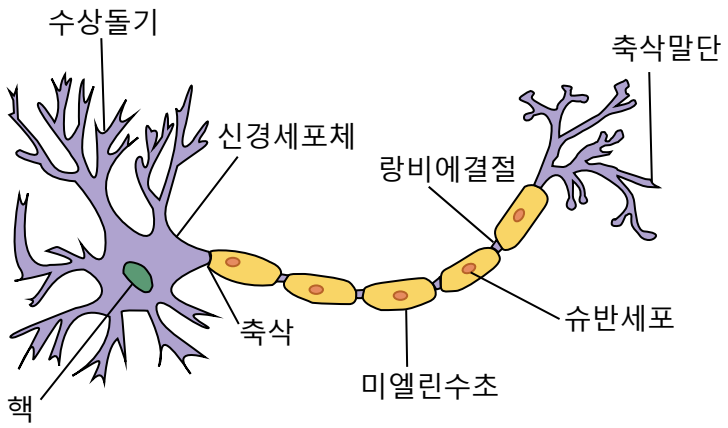

뉴런의 동작원리

- 전기 입력을 받아 또 다른 전기 신호를 발생시킴
- 뉴런을 입력을 받았을 때 즉시 반응하지 않고 입력이 누적되어 어떤 수준으로 커진 경우에만 출력이 발생함(활성화 상태)

https://www.google.com/url?sa=i&url=https%3A%2F%2Fnamu.wiki%2Fw%2F%25EB%2589%25B4%25EB%259F%25B0&psig=AOvVaw1yYdmf_abQBXIz31zGE0Xe&ust=1713869467459000&source=images&cd=vfe&opi=89978449&ved=0CBIQjRxqFwoTCIDD3LjT1YUDFQAAAAAdAAAAABAE

딥러닝(Deep Learning) 개념

➢ 딥러닝 (Deep Learning)

뇌(brain)의 정보처리방식을 모사한 인공신경망과 유사하게 여러 층(Layer)으로 깊이 있기(Deep) 구성하여 학습을 진행하는 머신러닝 알고리즘

❖ 딥러닝 기본 개념

- **뉴런 vs 인공신경망**

뉴런	인공신경망
전기 **입력을 받아** 또 다른 전기 **신호 발생**시킴	인공신경망(분류/예측기)이 **입력을 받아** 어떤 처리를 통해 **결과를 출력**
입력 받았을 때 즉시 반응하지 않고 입력이 누적되어 **어떤 수준**에 도달해야 전기 신호(출력) 발생 → 어떤 수준 : **분계점(Threshold, 한곗값)** → 전기 신호가 발생하는 상태 : **활성화(Activation) 상태**	입력신호를 받아 누적된 입력이 분계점을 넘어설 때 출력신호를 생성하는 함수**(활성화 함수)**를 사용

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

딥러닝(Deep Learning) 개념

➢ **딥러닝 (Deep Learning)**

뇌(brain)의 정보처리방식을 모사한 인공신경망과 유사하게 여러 층(Layer)으로 깊이 있기(Deep) 구성하여 학습을 진행하는 머신러닝 알고리즘

❖ **딥러닝 기본 개념**

- **뉴런 vs 인공신경망**
  - 실제 사람의 뇌는 여러 개의 뉴런으로 구성(약 1천억 개)
  - 각 뉴런은 1개가 아닌 여러 개의 뉴런으로부터 입력을 받고, 활성화될 때 여러 개의 뉴런으로 신호를 전달

뉴런, 뇌구조 :

심층신경망 DNN :

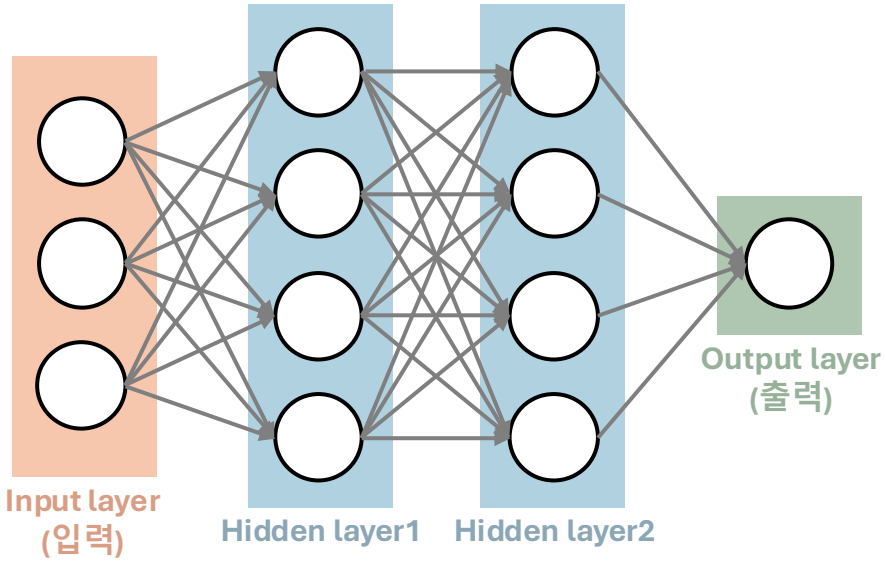

https://www.google.com/url?sa=i&url=https%3A%2F%2Fnamu.wiki%2Fw%2F%25EB%2589%25B4%25EB%259F%25B0&psig=AOvVaw1yYdmf_abQBXIz31zGE0Xe&ust=1713869467459000&source=images&cd=vfe&opi=89978449&ved=0CBIQjRxqFwoTCIDD3LjT1YUDFQAAAAAdAAAAABAE

AI 구현 프로세스의 이해

1) 문제정의

문제정의

문제정의 : 목적과 목표를 명확히 하는 단계

- 무엇이 문제인가?
- 얻고자 하는 결과는 무엇인가?
- 이를 위해 무엇을 해야 하는가?

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

문제정의

- **AI가 적용될 수 있는 상황**

1. 데이터나 규칙이 너무 복잡한 경우
   - 복잡한 규칙을 프로그래밍해야 하는 경우 시간과 비용이 증가 → AI 활용해 규칙을 스스로 학습
2. 다양한 형태의 데이터를 활용할 경우
   - 반정형 / 비정형 데이터
3. 파악하지 못한 영역의 연구와 해결이 필요한 경우
   - 지도학습 : 과거 데이터 기반으로 미래의 상황을 예측
   - 비지도학습 : 수집된 데이터 간의 숨겨진 특성을 캡쳐
   - 강화학습 : 사람이 예상치 못한 방식으로 해답을 찾음

   → 규칙을 찾아내는 AI의 능력은 미지의 영역을 개척할 수 있는 가능성을 제시

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

문제정의

- **AI 주요 기능**

기능	용도	종류
예측 (Prediction)	데이터를 학습하고 패턴을 파악해 결과 예측	귀추 예측, 선호 예측, 맥락 예측
생성 (Generation)	텍스트, 음성, 사진, 동영상 등 생성	심미적 생성, 실용적 생성
소통 (Conversation)	기계에 대화 기능을 부여해 답변과 질문을 다양하게 연출	응대, 대화
자동화 (Automation)	사람에게 의지하지 않고 더 효율적인 방법을 찾아 최적화	자동 처리, 자동 최적화, 의사결정 자동화
인식 (Recognition)	대상의 다양한 특성을 인지하고 상황 판단	이미지 인식, 음성 인식, 감정 인식, 맥락 인식

→ 해결하고자 하는 문제를 **예측, 생성, 소통, 자동화, 인식과 같은 태스크로 재정의**하여 문제를 해결할 수 있다.

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

AI 구현 프로세스의 이해

2) 데이터 수집

데이터 수집

- **데이터 수집**

  : AI를 이용해 문제를 해결하기 위해 학습에 필요한 데이터를 수집하는 것

- **데이터 수집 방법**

  1. **무엇을 수집할 것인가?**

     → 어떤 데이터가 필요한지 정의

  2. **어떻게 수집할 것인가?**

     → 구체적인 데이터 획득 방안 수립

  3. **어떤 상태의 데이터를 수집해야 하는가?**

     → AI가 학습할 수 있는 데이터인지 확인

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

AI 구현 프로세스의 이해

3) 데이터 분석

데이터 분석

- **데이터 분석**

  : 수집한 데이터 안에서 어떤 것이 중요한 특성을 가지는지 찾는 과정

- **데이터 분석 방법**
  - ➢ **데이터 타입(Type) 확인**
  - ➢ **비시각화 분석**
  - ➢ **시각화 분석**

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

1) 데이터 타입 확인

1. **수치형(Numerical)**

   숫자로만 구성된 데이터

   - 연속형 데이터 : 값 사이의 간격없이 연속적인 값을 가지는 데이터
   - 이산형 데이터 : 셀 수 있는 값으로 표현되는 데이터

2. **문자형(Object or String)**

   문자로만 이루어지거나 문자와 숫자로 구성된 데이터

3. **범주형(Categorical)**

   수치형이나 문자형처럼 보이지만, 범주를 나눌 수 있는 데이터, 사칙연산이 불가능

   - 순서형(Ordinal) : 범주로 구분되며, 순서를 매길 수 있는 데이터
   - 명목형(Norminal) : 범주로 구분되며, 순서를 매길 수 없는 데이

4. **불리언형(Boolean)**

   논리값이 참/거짓으로 이루어진 데이터

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

1) 데이터 타입 확인

- 데이터
  - 수치형 (Numerical)
    - 연속형 — 값 사이의 간격없이 연속적인 값을 가지는 데이터 (예 : 키, 시간)
    - 이산형 — 셀 수 있는 값으로 표현되는 데이터 (예 : 사람 수, 물건 수)
  - 문자형 (Object) — 문자로만 이루어지거나 문자와 숫자로 구성된 데이터 (예 : 로그인 ID)
  - 범주형 (Categorical)
    - 순서형 — 범주로 구분되며, 순서를 매길 수 있는 데이터 (예 : 학점)
    - 명목형 — 범주로 구분되며, 순서를 매길 수 없는 데이터 (예 : 남녀)
  - 불리언형 (Boolean) — 논리값이 참과 거짓 중 하나로 표현되는 데이터

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

2) 비시각화 분석

➢ **기술 통계(Descriptive Statistics) 확인**

수집한 데이터를 통계적인 방법을 활용해 요약하여 설명

- **데이터가 어떻게 '모여' 있는지 표현하는 통계량**

1. **평균값(Mean)** : 각 데이터를 모두 더한 후 데이터 개수로 나눈 값
2. **중앙값(Median)** : 데이터를 크기 순서대로 배열했을 때 중앙에 위치하는 값
3. **최빈값(Mode)** : 데이터 중에서 빈도수가 가장 큰 값

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

2) 비시각화 분석

➢ 기술 통계(Descriptive Statistics) 확인

수집한 데이터를 통계적인 방법을 활용해 요약하여 설명

- **데이터가 어떻게 '모여' 있는지 표현하는 통계량**

1. **평균값(Mean)** : 각 데이터를 모두 더한 후 데이터 개수로 나눈 값
2. **중앙값(Median)** : 데이터를 크기 순서대로 배열했을 때 중앙에 위치하는 값
3. **최빈값(Mode)** : 데이터 중에서 빈도수가 가장 큰 값

데이터 : **1, 1, 1, 1, 2, 3, 3, 5, 10**

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

2) 비시각화 분석

➢ 기술 통계(Descriptive Statistics) 확인

수집한 데이터를 통계적인 방법을 활용해 요약하여 설명

- **데이터가 어떻게 '모여' 있는지 표현하는 통계량**

1. **평균값(Mean)** : 각 데이터를 모두 더한 후 데이터 개수로 나눈 값
2. **중앙값(Median)** : 데이터를 크기 순서대로 배열했을 때 중앙에 위치하는 값
3. **최빈값(Mode)** : 데이터 중에서 빈도수가 가장 큰 값

데이터 : **1, 1, 1, 1, 2, 3, 3, 5, 10**

평균값(Mean) :

$$\frac{1+1+1+1+2+3+3+5+10}{9} = 3$$

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

2) 비시각화 분석

➢ 기술 통계(Descriptive Statistics) 확인

수집한 데이터를 통계적인 방법을 활용해 요약하여 설명

- **데이터가 어떻게 '모여' 있는지 표현하는 통계량**

1. **평균값(Mean)** : 각 데이터를 모두 더한 후 데이터 개수로 나눈 값
2. **중앙값(Median)** : 데이터를 크기 순서대로 배열했을 때 중앙에 위치하는 값
3. **최빈값(Mode)** : 데이터 중에서 빈도수가 가장 큰 값

데이터 : **1, 1, 1, 1, 2, 3, 3, 5, 10**

↓

중앙값(Median) : 2

*** 만약 데이터의 수가 짝수인 경우 중앙에 있는 2개의 값을 평균하여 중앙값을 결정한다. ***

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

2) 비시각화 분석

➢ 기술 통계(Descriptive Statistics) 확인

수집한 데이터를 통계적인 방법을 활용해 요약하여 설명

- **데이터가 어떻게 '모여' 있는지 표현하는 통계량**

1. **평균값(Mean)** : 각 데이터를 모두 더한 후 데이터 개수로 나눈 값
2. **중앙값(Median)** : 데이터를 크기 순서대로 배열했을 때 중앙에 위치하는 값
3. **최빈값(Mode)** : 데이터 중에서 빈도수가 가장 큰 값

데이터 : **1, 1, 1, 1, 2, 3, 3, 5, 10**

→ **최빈값(Mode) : 1**

*** 빈도수가 가장 큰 값이 두 개 이상인 경우, 최빈값은 여러 개가 될 수 있다. ***

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

2) 비시각화 분석

➢ 기술 통계(Descriptive Statistics) 확인

수집한 데이터를 통계적인 방법을 활용해 요약하여 설명

- **데이터가 어떻게 '흩어져' 있는지 표현하는 통계량**

1. **최솟값(Minimum)** : 데이터 중 가장 작은 값
2. **최댓값(Maximum)** : 데이터 중 가장 큰 값
3. **분산(Variance)** : 각 데이터에서 평균을 뺀 차이 값. 제곱의 평균
4. **표준편차(Standard Deviation)** : 분산의 제곱근
5. **사분위수(Quartile)** : 모든 데이터를 배열했을 때, 4등분한 지점에 있는 값
6. **첨도(Kurtosis)** : 데이터 분포가 정규분포 대비 뾰족한 정도를 나타내는 값
7. **왜도(Skewness)** : 데이터 분포가 정규분포 대비 비대칭한 정도를 나타내는 값

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

2) 비시각화 분석

➢ 기술 통계(Descriptive Statistics) 확인

수집한 데이터를 통계적인 방법을 활용해 요약하여 설명

- **데이터가 어떻게 '흩어져' 있는지 표현하는 통계량**

1. **최솟값(Minimum)** : 데이터 중 가장 작은 값
2. **최댓값(Maximum)** : 데이터 중 가장 큰 값
3. **분산(Variance)** : 각 데이터에서 평균을 뺀 차이 값. 제곱의 평균
4. **표준편차(Standard Deviation)** : 분산의 제곱근
5. **사분위수(Quartile)** : 모든 데이터를 배열했을 때, 4등분한 지점에 있는 값
6. **첨도(Kurtosis)** : 데이터 분포가 정규분포 대비 뾰족한 정도를 나타내는 값
7. **왜도(Skewness)** : 데이터 분포가 정규분포 대비 비대칭한 정도를 나타내는 값

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

2) 비시각화 분석

➢ 기술 통계(Descriptive Statistics) 확인

수집한 데이터를 통계적인 방법을 활용해 요약하여 설명

- **데이터가 어떻게 '흩어져' 있는지 표현하는 통계량**

1. **최솟값(Minimum)** : 데이터 중 가장 작은 값
2. **최댓값(Maximum)** : 데이터 중 가장 큰 값

데이터 : **1, 1, 1, 1, 2, 3, 3, 5, 10**

↓ **최솟값(Minimum) : 1**

↓ **최댓값(Maximum) : 10**

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

2) 비시각화 분석

➢ **기술 통계(Descriptive Statistics) 확인**

수집한 데이터를 통계적인 방법을 활용해 요약하여 설명

- **데이터가 어떻게 '흩어져' 있는지 표현하는 통계량**

3. **분산(Variance)** : 각 데이터에서 평균을 뺀 차이 값. 제곱의 평균
4. **표준편차(Standard Deviation)** : 분산의 제곱근

데이터 : **1, 1, 1, 1, 2, 3, 3, 5, 10**

분산(Variance) : $$\frac{(1-3)^2+(1-3)^2+(1-3)^2+(1-3)^2+(2-3)^2+(3-3)^2+(3-3)^2+(5-3)^2+(10-3)^2}{9} = 7.78$$

표준편차(Standard Deviation) : $\sqrt{7.78} = 2.79$

➔ 분산과 표준편차는 <u>데이터가 평균으로부터 얼마나 떨어져 있는지</u>를 나타내는 지표임

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

2) 비시각화 분석

➢ 기술 통계(Descriptive Statistics) 확인

수집한 데이터를 통계적인 방법을 활용해 요약하여 설명

- **데이터가 어떻게 '흩어져' 있는지 표현하는 통계량**

  5. **사분위수(Quartile)** : 모든 데이터를 배열했을 때, 4등분한 지점에 있는 값

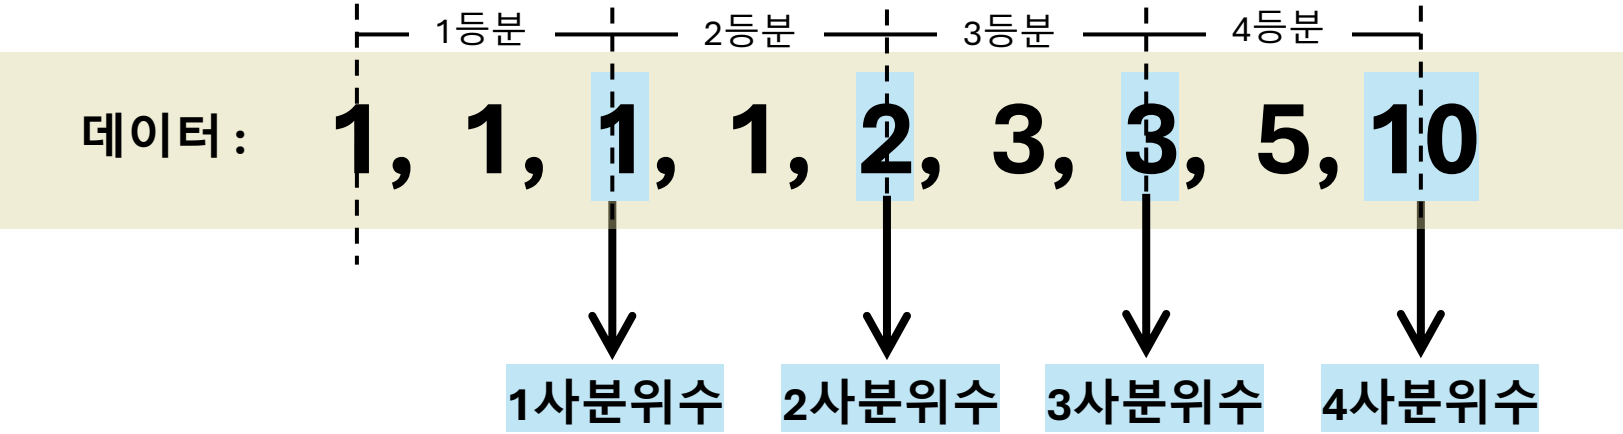

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

2) 비시각화 분석

➢ 기술 통계(Descriptive Statistics) 확인

수집한 데이터를 통계적인 방법을 활용해 요약하여 설명

- **데이터가 어떻게 '흩어져' 있는지 표현하는 통계량**

6. **첨도(Kurtosis)** : 데이터 분포가 정규분포 대비 뾰족한 정도를 나타내는 값
7. **왜도(Skewness)** : 데이터 분포가 정규분포 대비 비대칭한 정도를 나타내는 값

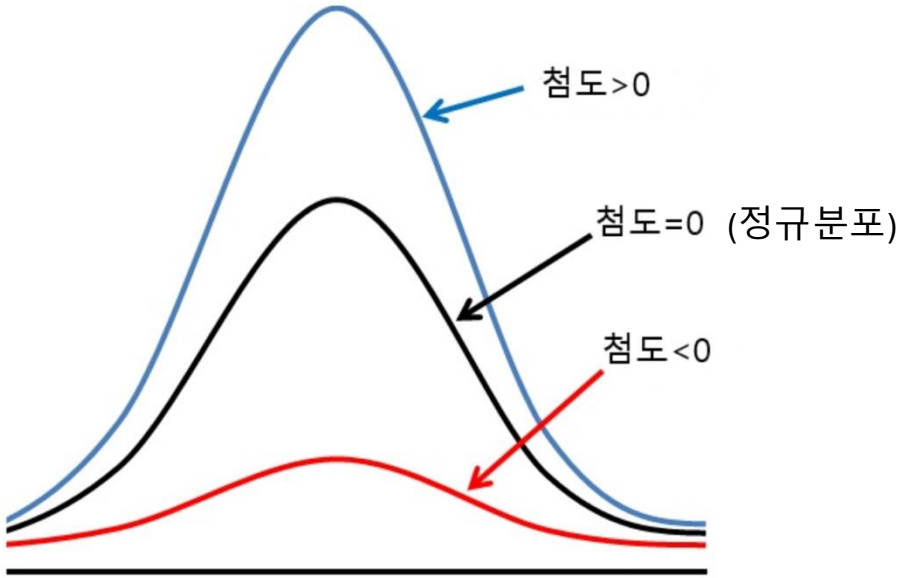

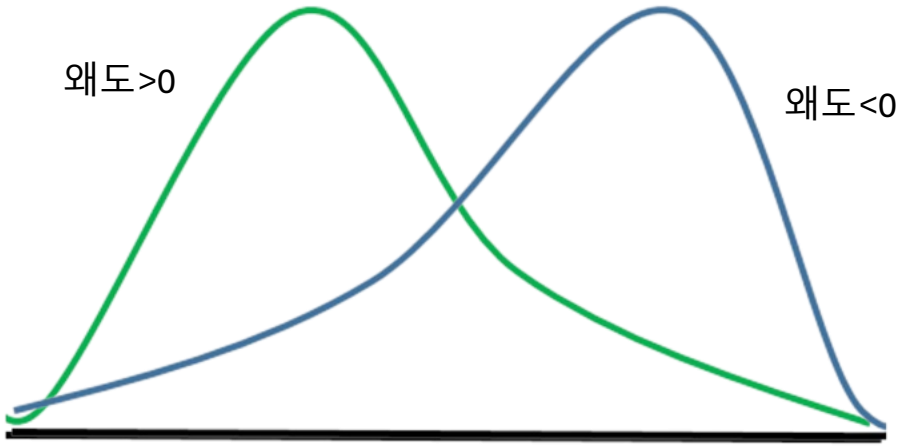

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

2) 비시각화 분석

➢ **기술 통계(Descriptive Statistics) 확인**

수집한 데이터를 통계적인 방법을 활용해 요약하여 설명

- **다변량 비시각화 탐색**
  - ◆ **상관계수** : 수치형 데이터의 상관관계를 확인
    - 두 변수 간의 선형 상관관계를 계량화한 수치
    - **-1 과 +1 사이의 값**을 가지며, **1에 가까울수록 강한 양의 상관관계**, **-1에 가까울수록 강한 음의 상관관계**, **0에 가까울수록 상관관계가 없다**는 것을 의미

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

3) 시각화 분석

➢ 데이터 시각화 (Visualization)

데이터 분석 결과를 쉽게 이해하도록 시각적으로 표현하고 전달하는 과정

- **일변량 시각화** : 1개의 변수만 분석
  1. **막대 그래프(Bar Plot) 또는 카운트플롯(Count Plot)**
  2. **히스토그램(Histogram)**
  3. **상자 그래프(Box Plot)**
- **다변량 시각화** : 2개 이상의 변수 간의 관계를 분석
  1. **산점도(Scatter Plot)**
  2. **히트맵(Heatmap)**

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

3) 시각화 분석 – 일변량 시각화

1. 막대 그래프(Bar Plot) 또는 카운트플롯(Count Plot)

: 범주에 대한 통계 데이터나 양(개수)을 막대 모양으로 나타내는 그래프

- 각 항목의 수량 한눈에 파악 쉬움
- 크고 작음의 비교 가능
- 사용 목적이나 가독성을 고려해 가로/세로/누적/그룹화된 막대 그래프 사용 가능

[항공권 가격 예측 데이터]

세로축 : 항공권 가격

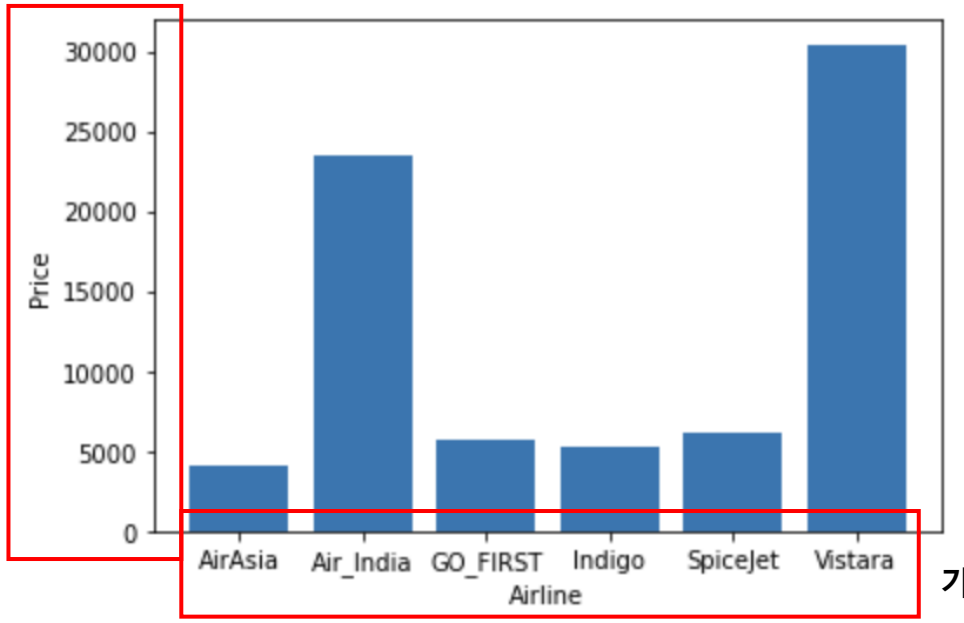

가로축 : 항공사 이름

가로축 : 각 범주
세로축 : 범주별 통계 데이터

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

3) 시각화 분석 – 일변량 시각화

2. 히스토그램(Histogram)

: 수치형 데이터의 구간별 빈도수를 막대 모양으로 표시한 그래프

- 데이터의 특성과 분포를 파악하기 쉬움
- 빈도, 빈도밀도, 확률 등의 분포를 그릴 때 사용
- **분포차트(Density Plot)** : 여러 범주를 다룰 때, 서로 다른 범주를 색상으로 구분하여 범주에 따른 분포를 비교할 수 있다.

가로축 : 수치형 데이터 구간
세로축 : 구간에 해당하는 데이터 빈도수

[목적지까지 소요 시간 분포]

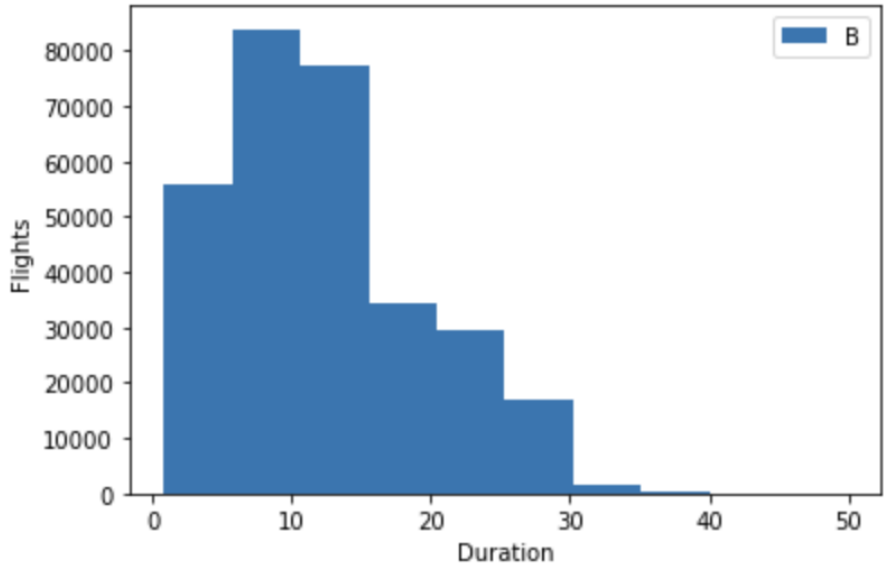

[분포차트 : 목적지까지 소요 시간 분포]

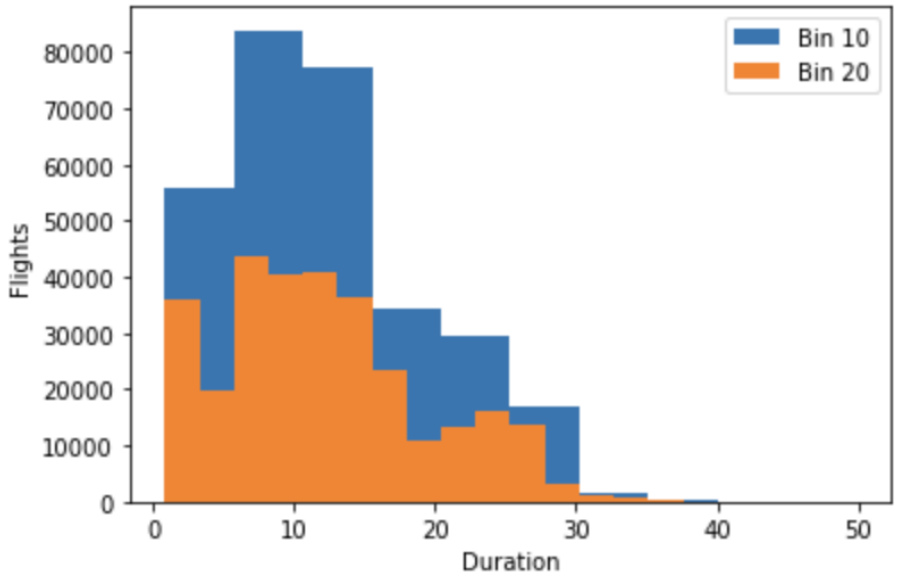

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

3) 시각화 분석 – 일변량 시각화

3. 상자 그래프(Box Plot)

: 사분위수를 중심으로 수치형 데이터의 통계정보를 박스모양으로 시각화하는 그래프

- 수치자료로 얻어낸 5가지 통계량(상단경계, 제1사분위수, 중앙값, 제3사분위수, 하단경계)을 시각화하여 데이터 이해 가능
- 데이터의 분포와 이상치 등 통계적 특성을 한눈에 파악할 수 있음
- **이상치(outlier)** : 정해진 최댓값보다 크거나 정해진 최솟값보다 작은 값

상단경계 : 제3사분위수 + 1.5*IQR보다 작은 값 중 최댓값
하단경계 : 제1사분위수 – 1.5*IQR보다 큰 값 중 최솟값

**** IQR (Interquartile range) :**
(제3사분위수) – (제1사분위수)

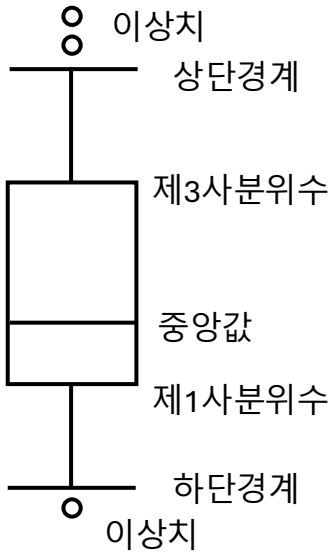

[항공권 데이터의 데이터 요약 통계 및 분포]

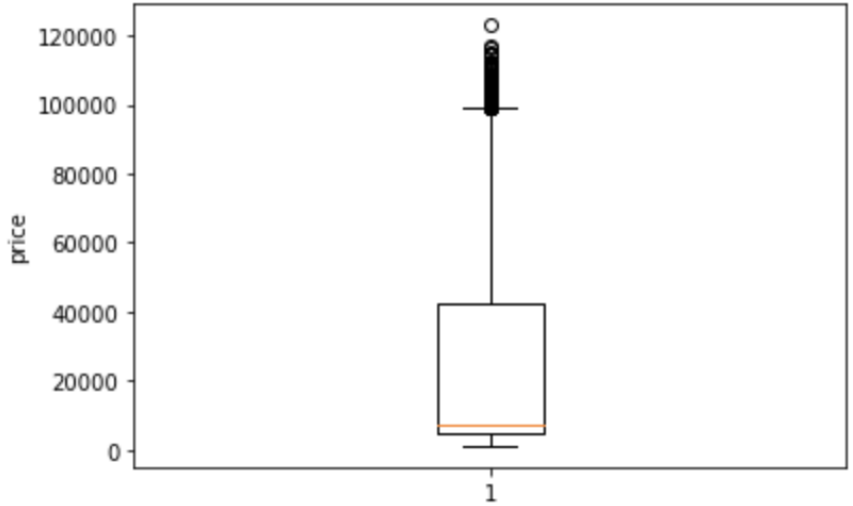

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

3) 시각화 분석 – 일변량 시각화

3. 상자 그래프(Box Plot)

- 상자 그래프의 주요 지표

지표	설명
최솟값(Minimum)	해당 범주 내 데이터 중 가장 작은 값
하단 경계(Lower Fence)	박스 바깥의 하단에 있는 선으로, Q1 – (1.5*IQR) 위치
Q1, 1사분위수	박스 하단의 선으로, 데이터 분포상 25%(4 분의 1) 위치에 있는 값
중앙값(Median)	박스 중간의 선으로, 데이터 분포 중 50%(중앙)에 위치한 값
Q3, 3사분위수	박스 상단의 선으로, 데이터 분포 중 75%(4 분의 3)에 위치한 값
상단 경계(Upper Fence)	박스 바깥의 상단에 있는 선으로, Q3 + (1.5*IQR) 위치
최댓값(Maximum)	해당 범주 내 데이터 중 가장 큰 값
IQR(InterQuartile Range)	Q1과 Q3 사이 거리
이상치(Outlier)	통계적으로 하단 경계와 상단 경계를 벗어나는 값

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

3) 시각화 분석 – 다변량 시각화

1. 산점도(Scatter Plot)

: 두 수치형 데이터 사이의 관계를 보여주는 시각화 방법

- 두 변수 간의 대략적인 상관관계 확인

[비행시간(duration)과 항공권 가격(price)의 관계]

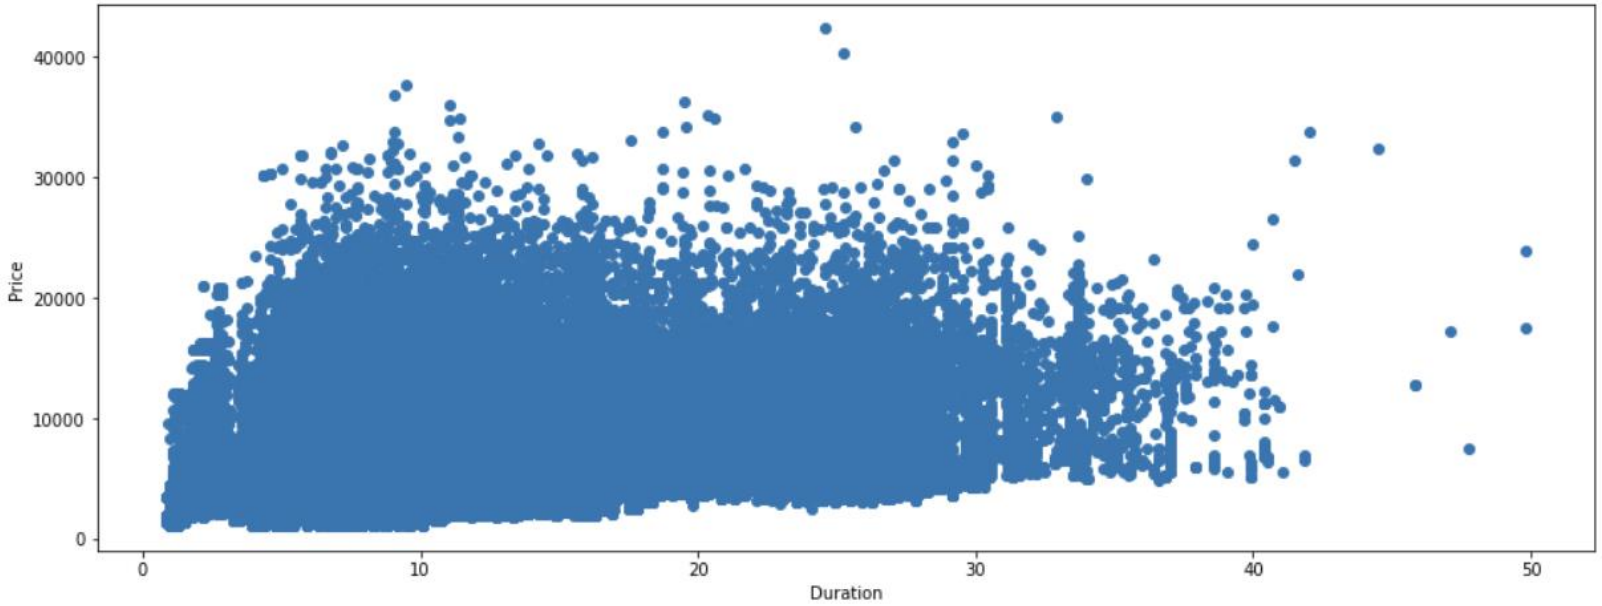

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

3) 시각화 분석 – 다변량 시각화

2. 히트맵(Heatmap)

: 두 데이터 간의 상관관계를 색상으로 표현해주는 그래프

- 두 값 또는 각 컬럼 간의 상관관계를 나타낼 때 주로 사용
- -1~1사이의 값을 가지며, 1에 가까울수록 두 데이터의 상관도는 양의 값으로 비례(양의 상관관계)하고, -1에 가까울수록 음의 값으로 비례(음의 상관관계) 함

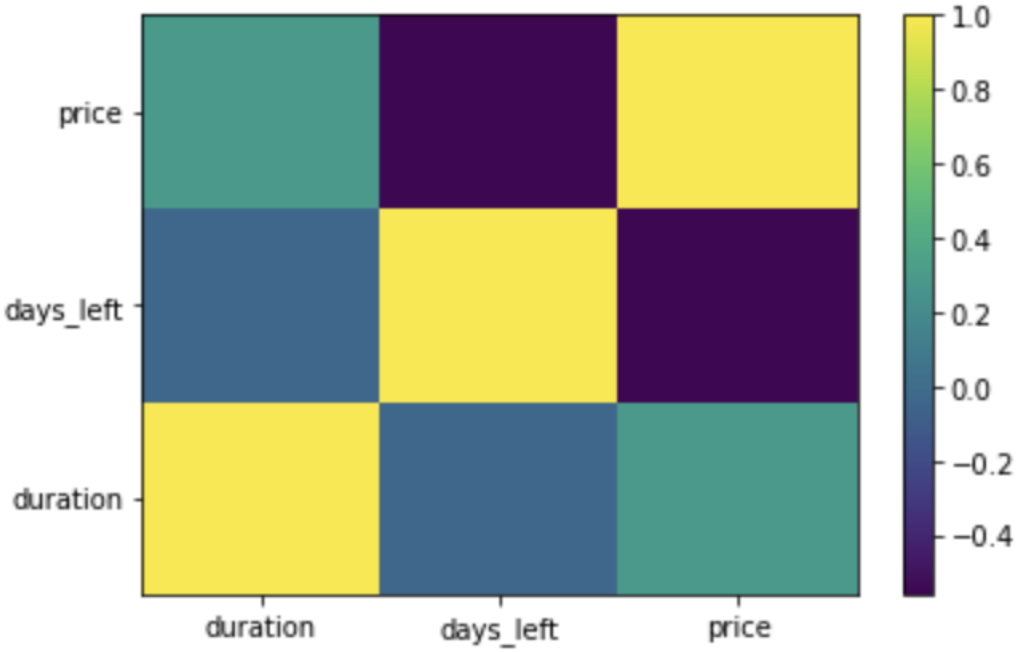

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

AI 구현 프로세스의 이해

4) 데이터 전처리 1

[결측치, 이상치 처리]

1) 결측치 처리

- **결측치 (Missing Value 또는 Null)**

  데이터에 값이 없는 것

  → 결측치가 포함된 경우, 후속으로 데이터 분석과 AI모델링 진행을 할 수 없다.

➢ **결측치 처리**

1. **제거(Drop)**
2. **대체(fill)**

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

1) 결측치 처리

1. 제거(Drop)

- 데이터가 충분히 많은 경우
- 결측치가 대세에 큰 영향을 미치지 않는 경우
- 결측치의 비중이 적은 경우

→ 결측치를 쉽게 처리할 수 있지만, 데이터의 손실이 반드시 생기기 때문에 원래 데이터의 특성을 모두 반영하지 못할 수 있다.

**** 0은 결측값이 아님.**
**** 결측값은 N/A, NULL, NaN 등으로 표현됨**

No	Col1	Col2	Col3
0	1	0	0
1	0	1	
2	1	0	0
3	0		1
4	0	1	0

No	Col1	Col2	Col3
0	1	0	0
1	0	1	
2	1	0	
3	0	0	
4	0	1	

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

1) 결측치 처리

1. 제거(Drop)

- 데이터가 충분히 많은 경우
- 결측치가 대세에 큰 영향을 미치지 않는 경우
- 결측치의 비중이 적은 경우

→ 결측치를 쉽게 처리할 수 있지만, 데이터의 손실이 반드시 생기기 때문에 원래 데이터의 특성을 모두 반영하지 못할 수 있다.

**** 0은 결측값이 아님.**
**** 결측값은 N/A, NULL, NaN 등으로 표현됨**

행(Row) 단위 Drop

No	Col1	Col2	Col3
0	1	0	0
1	0	1	
2	1	0	0
3	0		1
4	0	1	0

열(Column) 단위 Drop

No	Col1	Col2	Col3
0	1	0	0
1	0	1	
2	1	0	
3	0	0	
4	0	1	

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

1) 결측치 처리

2. 대체(Fill)

- 데이터가 충분하지 않은 경우

→ 어떻게든 채워주어 최대한 모든 데이터를 AI가 학습할 수 있도록 한다.

❖ **수치형 데이터** 대체

평균값(Mean), 중앙값(Median), 최빈값(Mode)으로 대체, **상관관계** 또는 **예측모델의 예측값**으로 대체하는 것도 가능

❖ **범주형 데이터** 대체

최빈값(Mode)으로 대체, 전체적으로 유사한 특성을 가지는 **유사 벡터값**으로 대체하는 것도 가능

No	Col1(수치형)	Col2(수치형)	Col3(범주형)
0	1	0	A
1	0	1	
2	1	0	B
3	0		A
4	0	1	F

최빈값 'A' 또는 유사 벡터값 'F'로 대체
(1,4행이 Col1,Col2이 같으므로)

평균값 '0.33' 또는 중앙값 '1' 또는 선형회귀 예측값 '1'로 대체

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

2) 이상치 처리

- **이상치(Outlier)**

  전체 데이터의 추세/패턴 등에서 벗어난 값을 가진 데이터

  → 이상치가 존재하면 전체 추세/패턴을 벗어나는 데이터도 모델학습에 반영되어 모델 성능에 영향 미친다.

➢ **이상치 처리**

1. **이상치 탐지(Outlier Detection)**
2. **이상치 처리**

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

2) 이상치 처리

1. 이상치 탐지(Outlier Detection)

- 가장 널리 사용되는 방법은 IQR 값을 활용하는 방법

  → **상단 경계(Upper Fence(Q3 + IQR*1.5))**보다 크거나, **하단 경계(Lower Fence(Q1– IQR*1.5))**보다 작으면 통계적으로 이상치라고 부른다.

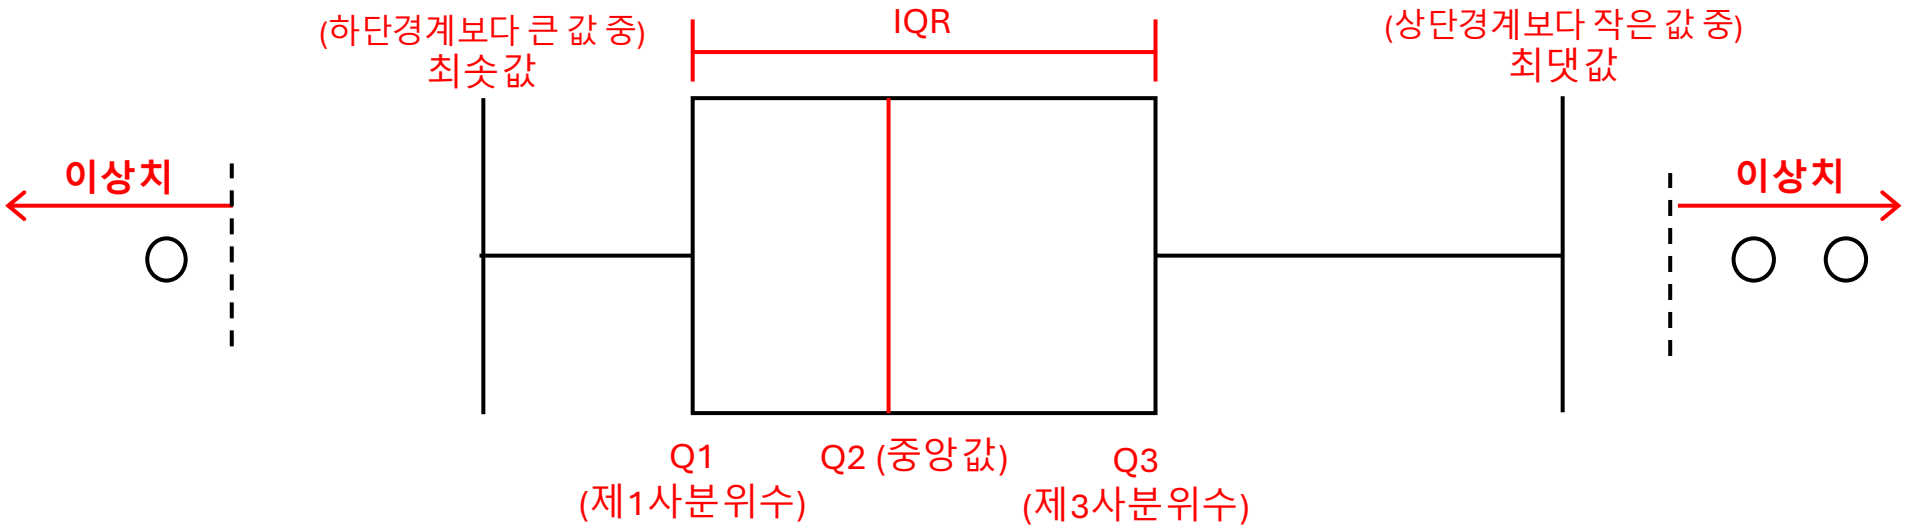

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

2) 이상치 처리

2. 이상치 처리

- 적당한 스케일링 기법을 적용해 그대로 사용
- 이상치를 포함하는 행을 삭제
- 이상치 경곗값(Q3 + IQR*1.5 또는 Q1 – IQR*1.5)으로 치환
- etc.

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

AI 구현 프로세스의 이해

4) 데이터 전처리 2

[인코딩, 스케일링]

3) 인코딩

➢ **인코딩 (Encoding)**

문자를 숫자로 바꿔주는 과정

- 문자형 데이터는 모델이 학습할 수 있는 형태인 숫자로 바꿔줘야 함

- **인코딩 방식**

1. **Ordinal Encoding (또는 Label Encoding)**
2. **One-hot Encoding**

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

3) 인코딩

1. Ordinal Encoding (또는 Label Encoding)

- 범주(카테고리)형 데이터에 숫자 레이블을 할당, 0,1,2, ... 차례대로 맵핑
- 할당된 숫자에 따라 순서가 생김

2. One-hot Encoding

- 1개의 요소는 1 (True), 나머지 요소는 0 (False)로 만들어 주는 기법
- 순서나 랭크가 없는 카테고리형 데이터를 바꾸는 데에 적합

[Ordinal Encoding]

1. **가나다순 정렬**
   대전→부산→서울
2. **순서대로 번호 부여**
   대전 – 0
   부산 – 1
   서울 - 2

거주지
서울
대전
부산
대전
서울

→

거주지
2
0
1
0
2

[One-hot Encoding]

거주지
서울
대전
부산
대전
서울

→

서울	대전	부산
1	0	0
0	1	0
0	0	1
0	1	0
1	0	0

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

4) 스케일링

➢ **스케일링 (Scaling)**

수치형 변수 간 비교를 위해 수치의 단위를 맞추려고 수치의 크기를 변경하는 과정

- 특정 컬럼의 수치들이 다른 컬럼의 수치보다 상대적으로 크면 해당 컬럼에 가중치(Weight)가 있다고 판단해 학습에 잘못된 영향을 줄 수 있음

- **스케일링 방식**

1. **정규화 스케일링 (Min-max Scaling)**
2. **표준화 스케일링 (Standard Scaling)**

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

3) 스케일링

1. 정규화 (Min-Max Scaling)

- 데이터의 범위를 0~1 사이로 변환
- 정규화 후 최솟값은 0, 최댓값은 1

$$x' = \frac{x_i - X\text{최솟값}}{X\text{의 최댓값} - X\text{의 최솟값}}$$

2. 표준화 (Standard Scaling)

- 평균이 0이고, 표준편차가 1인 표준 정규분포로 변환

$$x' = \frac{x_i - X\text{의 평균}}{X\text{의 표준편차}}$$

→ 표준화가 정규화보다는 상대적으로 이상치에 영향을 덜 받을 가능성이 있음

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

AI 구현 프로세스의 이해

5) AI 모델링

AI 모델링

➢ **AI 모델링**

데이터에 적합한 AI 알고리즘을 선택하고, 준비된 데이터를 기반으로 모델학습을 시키고 평가하며 개선하는 모든 과정

- **모델링 프로세스**

1. **데이터 준비 (X, y 데이터 분리 / 학습 데이터 분할)**
2. **모델 선택 (알고리즘 선택)**
3. **모델 학습**
4. **모델 성능 평가**

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

1) 데이터 준비

- **X, y 데이터 분리**
  - 종속변수를 y로.
  - 종속변수를 제외한 나머지 변수를 X로!

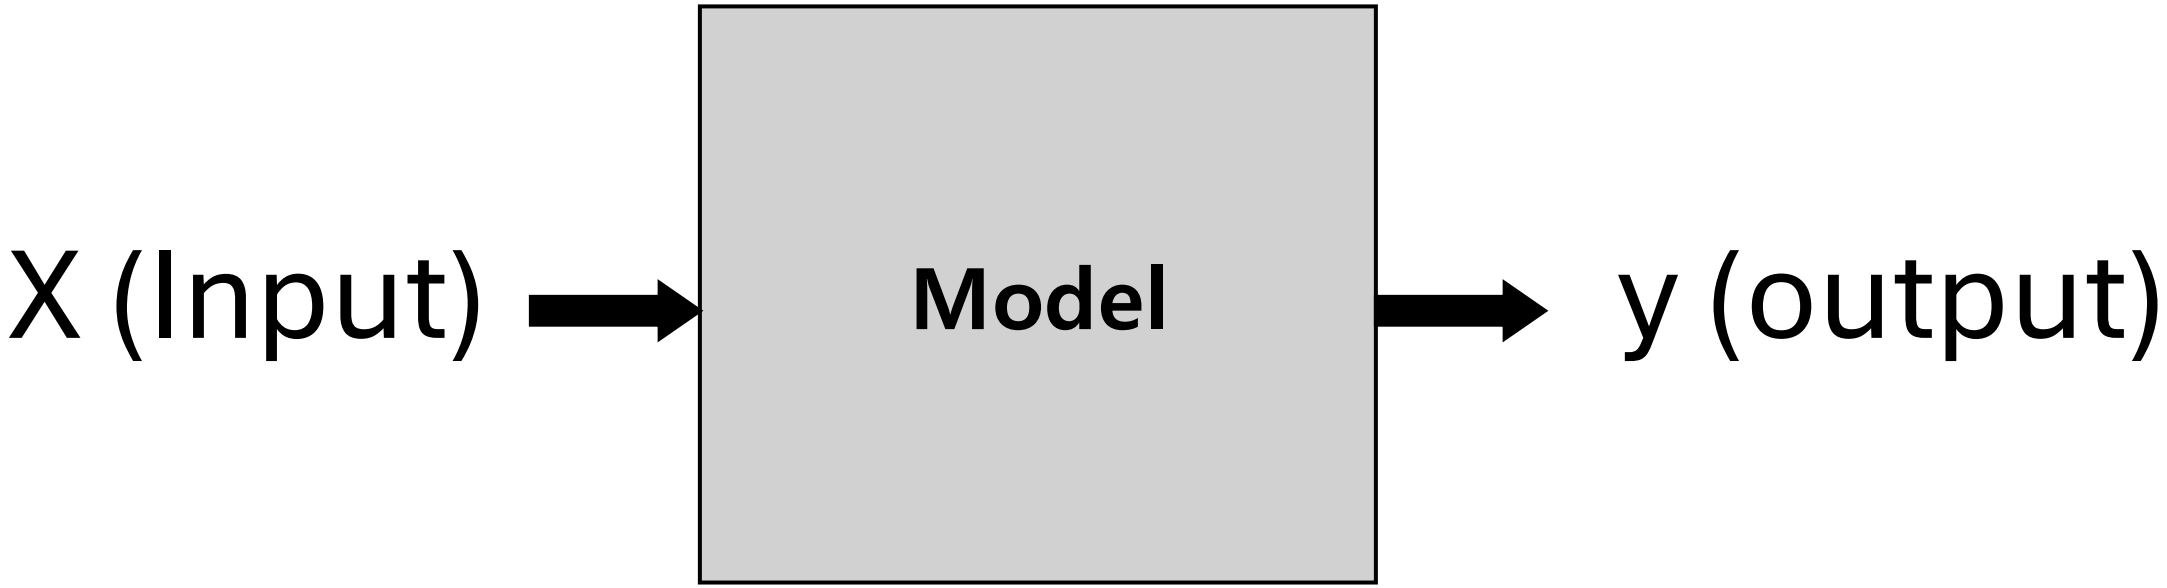

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

1) 데이터 준비

➢ 학습 데이터 분할

모델을 학습 및 평가하기 위해 **학습 데이터를 분할**

- **훈련(Train), 검증(Valid), 평가(Test)** 데이터로 분할 (7:1:2, 6:2:2 비율 등으로 **겹치지 않게** 분할)
- 훈련 데이터를 통해 모델 학습을 진행
- 검증 데이터를 통해 모델이 업데이트될 때마다 모델 성능을 측정
- 평가 데이터를 통해 최종 채택된 모델의 성능을 평가

→ **검증 데이터를 통해 모델의 성능을 평가하지만, 여러 번의 검증을 통해 가장 성능이 좋은 모델을 채택하게 되기 때문에 운 좋게 성능이 좋은 것이 채택되는 오차를 줄이기 위해 평가 데이터셋을 이용한 최종 평가를 수행.**

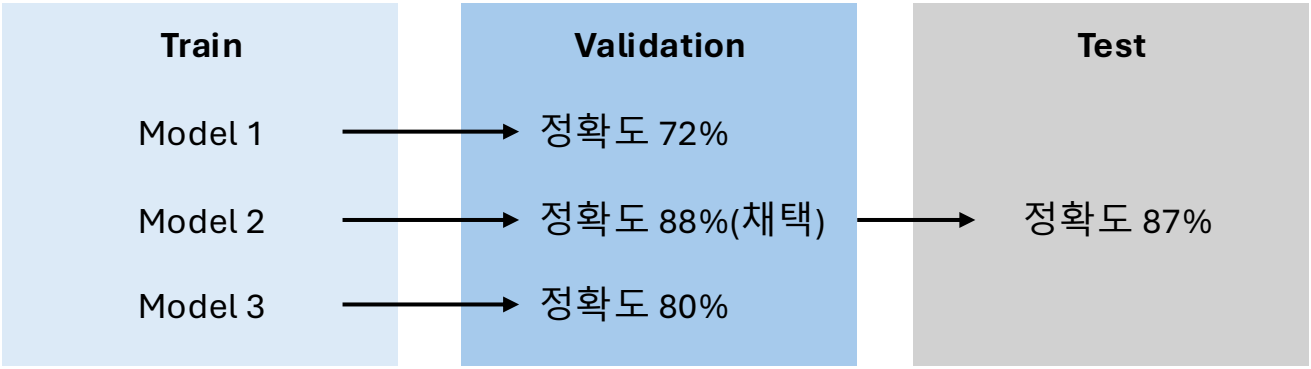

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

2) 모델 선택 (알고리즘 선택)

- 데이터 형태에 적합하도록 → 이미지? 텍스트? 테이블?
- **예측하고자 하는 결과값에 따라서 → 회귀? 분류?**
- 과제의 목적에 맞도록 → 예측? 설명?
- 투입할 수 있는 자원에 따라 선택 → 가벼운 모델? 무거운 모델?

예제 1)

A 카페를 운영하는 사장님은 AI 모델링을 통해 다음 주에 몇 잔의 커피가 팔릴지 정확히 예측하여 미리 적당한 양의 원두를 구매하고자 함

→ '예측'이 목적

예제 2)

B카페를 운영하는 사장님이 AI 모델링을 통해 커피 매출이 잘 나오는 달에 커피가 잘 팔리는 이유를 분석하고, 어떤 변수가 영향을 주는지 분석하고자 함

→ '설명'이 목적

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

3) 모델 학습

➢ 손실 함수(Loss Function)

신경망 학습의 목적 함수로 출력값(예측값)과 정답(실제값)의 차이를 계산

→ 모델학습이란 손실 함수(loss function)를 최소화하는 방향으로 AI 알고리즘 내에 있는 가중치(weight)를 계속 업데이트하는 과정

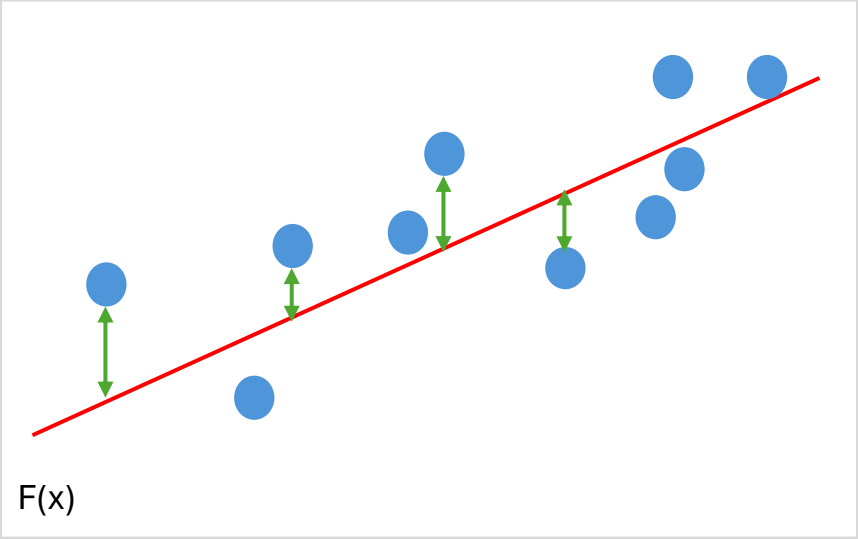

* 목적 함수 : 최소화/최대화하고 싶은 함수
* 가중치 : 출력값과 정답값을 비교하여 오차를 최소화하려고 임의의 값을 조금씩 조정하는 파라미터

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

3) 모델 학습

➢ 손실 함수(Loss Function)

신경망 학습의 목적 함수로 출력값(예측값)과 정답(실제값)의 차이를 계산

→ 모델학습이란 손실 함수(loss function)를 최소화하는 방향으로 AI 알고리즘 내에 있는 가중치(weight)를 계속 업데이트하는 과정

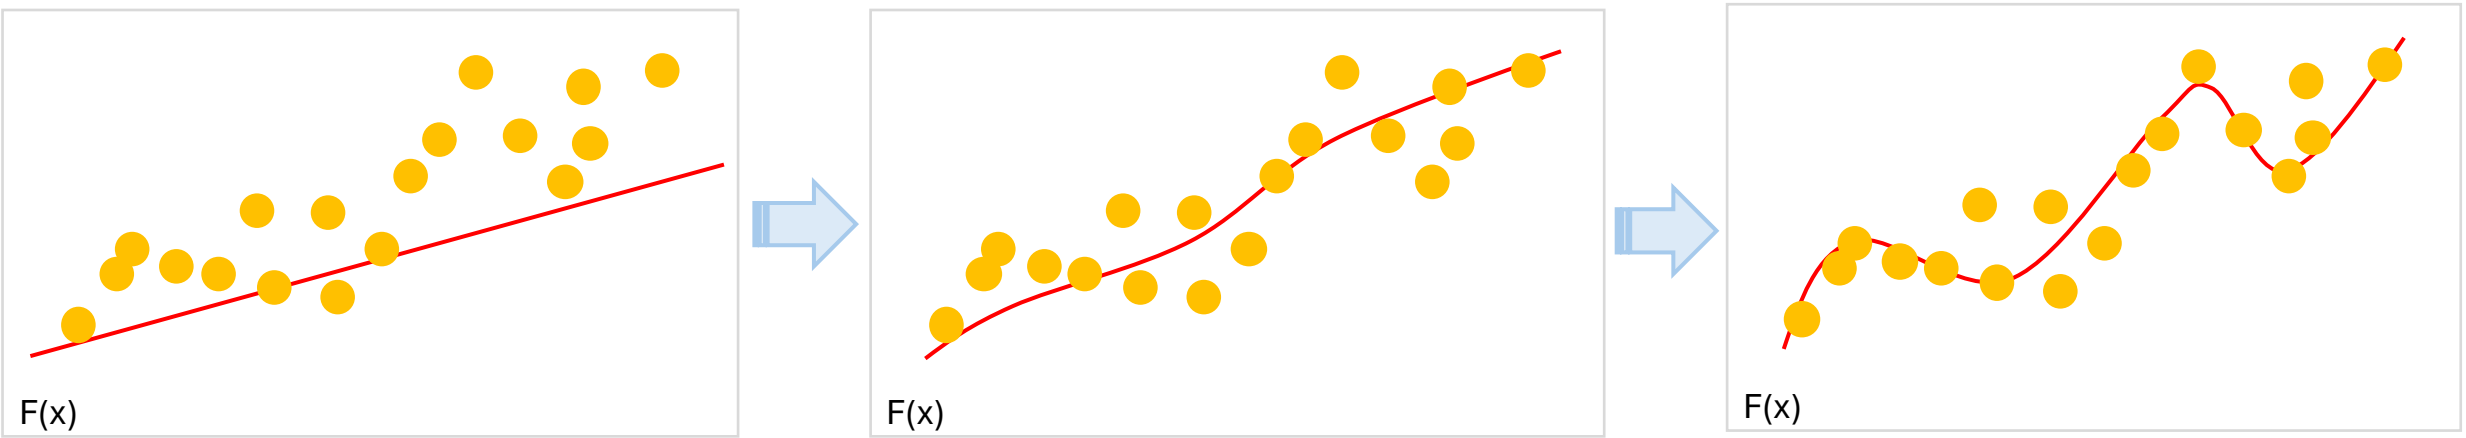

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

3) 모델 학습

❖ **과소적합(Under Fitting)**

학습을 너무 적게 진행한 상태

→ 학습 반복 횟수를 더 많이 늘려서 해결

❖ **과대적합(Over Fitting)**

모델이 훈련 데이터에 너무 편향된 상태

- **과대적합이 발생하는 경우**
  - 훈련 데이터가 대표성을 갖지 않는 경우
  - 훈련 데이터로 지나치게 많은 학습을 한 경우

→ 훈련 데이터에 대해서는 성능이 잘 나오지만, 검증 데이터나 평가 데이터에서는 성능이 잘 나오지 않음

→ Early Stop, Drop out 등을 기법 이용해 해결

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

3) 모델 학습

	과소적합	이상적 모델	과대적합
회귀	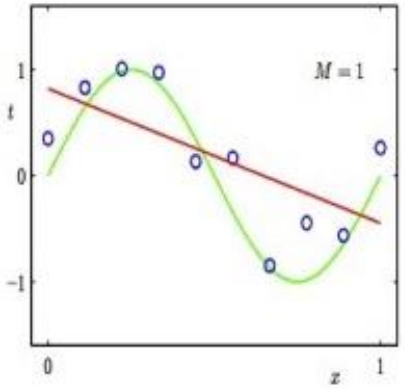	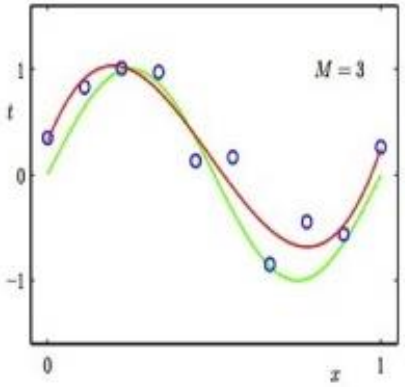	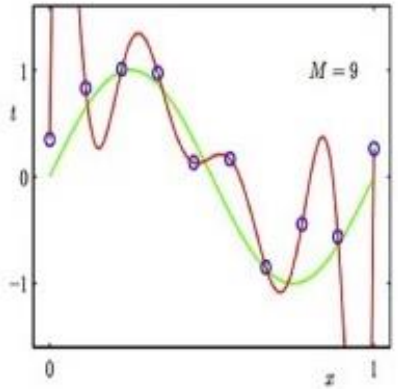
분류	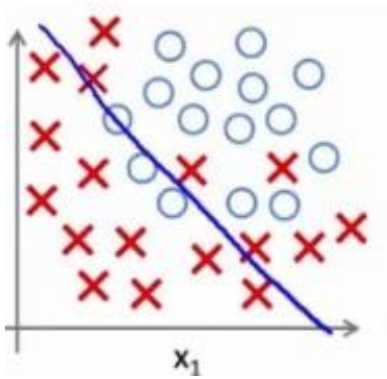	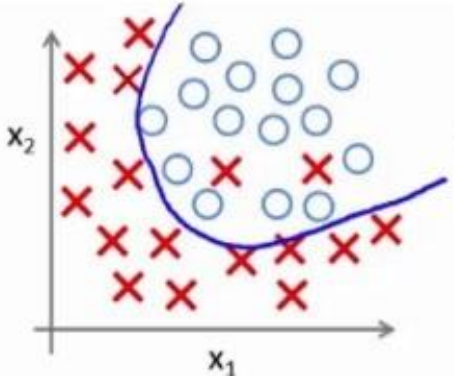	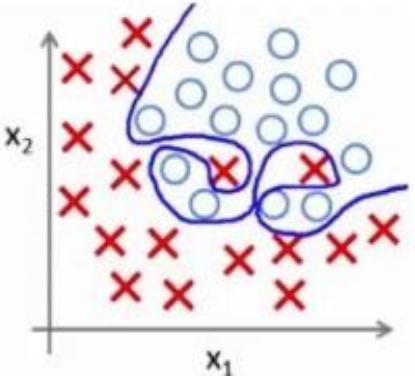

이미지출처: https://www.google.com/url?sa=i&url=https%3A%2F%2Fgithub-wiki-see.page%2Fm%2Fvotus777%2FAI_study%2Fwiki%2F04%25EC%259D%25BC%25EC%25B0%25A8-%255B-Overfitting-%255D&psig=AOvVaw32ILRjpo5PRnVcLw3BESm9&ust=1711987193446000&source=images&cd=vfe&opi=89978449&ved=0CBIQjRxqFwoTCIiUi8nvnoUDFQAAAAAdAAAAABAD

4) 모델 성능 평가

- 분류 모델 평가
  - Accuracy(정확도)
  - Recall(재현율)
  - Precision(정밀도)
  - F1-score
  - ROC, AUC
- 회귀 모델 평가
  - MAE(Mean Absolute Error, 평균 절대 오차)
  - MSE(Mean Squared Error, 평균 제곱 오차)
  - RMSE(Root Mean Squared Error, 평균 제곱근 오차)
  - R2 Score(결정 계수)

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

4) 모델 성능 평가

➢ 분류 모델 평가

- **Accuracy(정확도) :** 전체 데이터 중 AI 모델이 예측해 맞힌 비율
- **Recall(재현율) :** 실제 positive 중 AI 모델이 positive라고 예측해 맞힌 비율
- **Precision(정밀도) :** positive로 예측한 것 중 실제 positive인 비율
- **F1-score :** Recall(재현율)과 Precision(정밀도)의 조화 평균

앞의 T / F : 정답을 맞췄다 / 못맞췄다.
뒤의 P / N : 모델이 P / N 이라고 예측했다.

		정답	
		Positive	Negative
예측	Positive	TP (True Positive)	FP (False Positive)
	Negative	FN (False Negative)	TN (True Negative)

$$\text{Accuracy} = \frac{\sum(TP + TN)}{\sum(TP + FP + FN + TN)}$$

$$\text{Precision} = \frac{\sum TP}{\sum(TP + FP)}$$

$$\text{recall} = \frac{\sum TP}{\sum(TP + FN)}$$

$$\text{F1-score} = 2 * \frac{recall * precision}{recall + precision}$$

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

4) 모델 성능 평가

➢ 분류 모델 평가

- **ROC 곡선(Receiver Operation Curve)**

FPR(False Positive Rate)이 변함에 따른 TPR(True Positive Rate)의 변화를 그린 곡선

- **FPR(False Positive Rate)**
  - $\text{FPR}=\dfrac{\text{positive로 잘못(False)예측 (FP)}}{\text{negative로 잘(True)예측(TN)}+\text{positive로 잘못(False)예측(FP)}}$
  - **실제 Negative 중 Positive라고 잘못 예측한 비율**
  - 낮을수록 좋음
- **TPR(True Positive Rate)**
  - $\text{TPR}=\dfrac{\text{positive로 잘(True)예측 (TP)}}{\text{positive로 잘(True)예측(TP)}+\text{negative로 잘못(False)예측(FN)}}$
  - **실제 Positive 중 Positive라고 잘 예측한 비율**
  - 높을수록 좋음

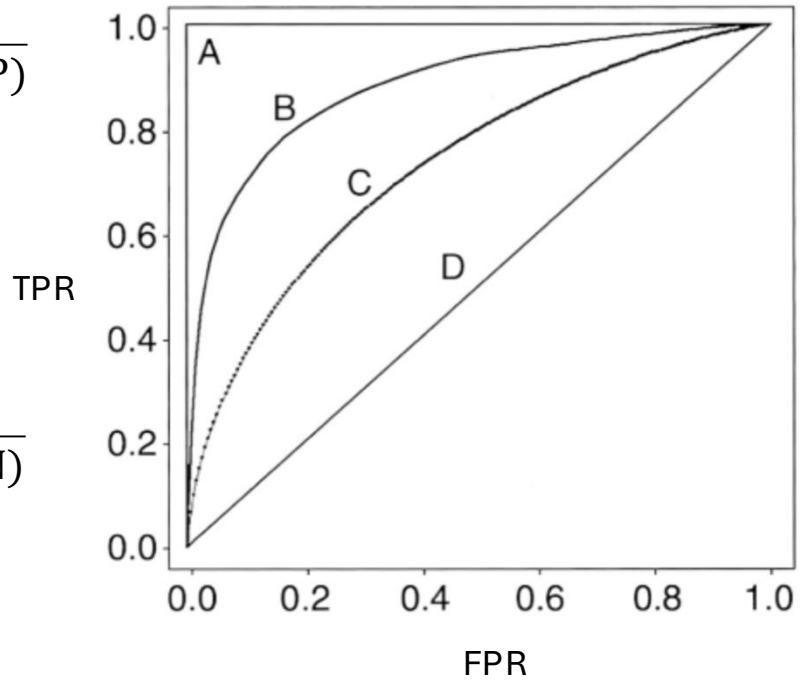

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

4) 모델 성능 평가

➢ 분류 모델 평가

- **ROC 곡선(Receiver Operation Curve)**

  FPR(False Positive Rate)이 변함에 따른 TPR(True Positive Rate)의 변화를 그린 곡선

  - A곡선과 D곡선을 비교했을 때, **곡선이 직각에 가까울수록 모델의 성능이 뛰어남**
  - D는 랜덤 모델로 볼 수 있는데, **Random에 가까울수록 성능이 나쁨**

- **AUC 면적(Area Under ROC)**

  ROC 곡선 아래의 면적

  - AUC 값이 클수록 성능이 좋음
  - 최대면적이 1이므로, **1에 가까울수록 성능이 좋다**고 볼 수 있다.
  - Random : 0.5

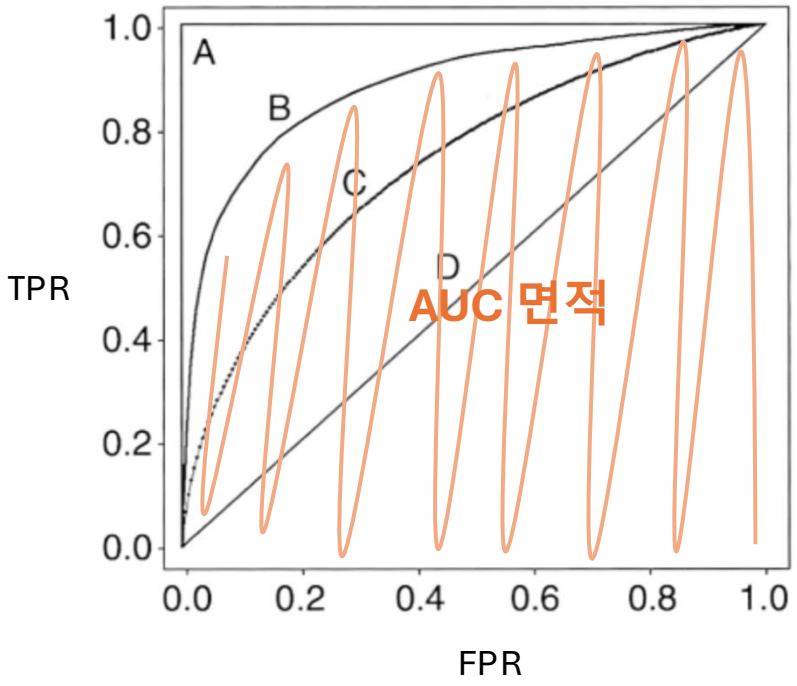

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

4) 모델 성능 평가

➢ **회귀 모델 평가** : 출력값(예측값)과 정답(실제값)의 차이를 계산

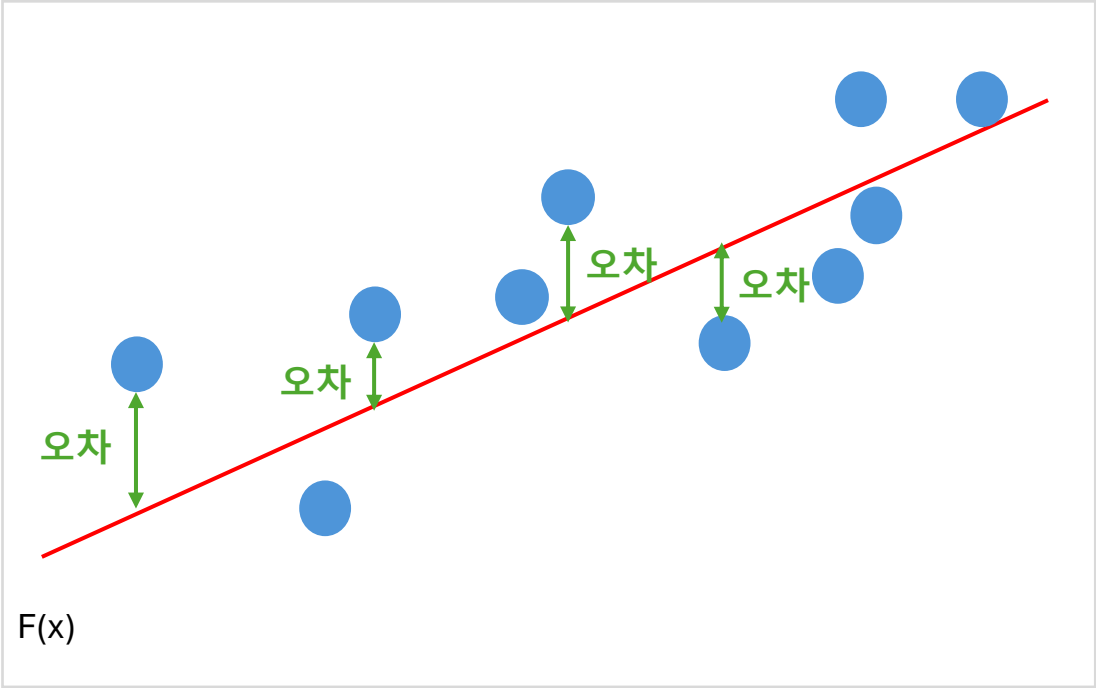

* 목적 함수 : 최소화/최대화하고 싶은 함수
* 가중치 : 출력값과 정답값을 비교하여 오차를 최소화하려고 임의의 값을 조금씩 조정하는 파라미터

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

4) 모델 성능 평가

➢ 회귀 모델 평가

- **Mean Absolute Error (평균 절대 오차, MAE)**

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|\text{실제값} - \text{예측값}|$$

- **Mean Squared Error (평균 제곱 오차 , MSE)**

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(\text{실제값} - \text{예측값})^2$$

- **Root Mean Squared Error (제곱근 평균 제곱 오차, RMSE)**

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(\text{실제값} - \text{예측값})^2}$$

- **R^2 (결정 계수)**

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(\text{실제값}-\text{예측값})^2}{\sum_{i=1}^{n}(\text{실제값}-\text{실제값의 평균})^2}$$

→ 0과 1사이 값, **1에 가까울수록 모델이 데이터를 잘 설명한다**

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

Python 데이터 분석 및 모델링

1) 파이썬 소개

파이썬(Python)이란?

파이썬(Python) : 1990년 암스테르담의 귀도 반 로섬(Fuido Van Rossum)이 개발한 인터프리터 언어
파이썬은 컴퓨터 프로그래밍 교육을 위해서 많이 사용하지만, 기업의 실무를 위해서도 많이 사용하는 언어이다.
(ex.구글, 인스타그램, 드롭박스, etc.)

- **파이썬 특징**
  1. 쉬운 문법
     인간의 사고방식을 모방(쉬운 이해), 간결한 코드(좋은 가독성)
  2. 무료이지만 강력
     빠른 개발속도, 오픈소스로 인한 개방성

→ 이러한 파이썬 특징에 의해 쉽게 데이터 분석 및 AI 모델링이 가능

* 인터프리터 언어 : 한 줄 씩 소스 코드를 해석해서 그때그때 실행해 결과를 바로 확인할 수 있는 언어

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

Python 데이터 분석 및 모델링

2) AIDU를 활용한 실습 환경 세팅

AICE 홈페이지의 AIDU 사용하기

AIDU : 설치가 필요 없는 웹 기반의 AI 모델링 환경과 용도 및 역량에 맞게 선택 가능한 AI 실습 툴

- **AIDU 실행하기**
  1. 아래 링크에 접속하여 우측 상단의 [회원가입] 후 로그인 (chrome으로 접속)
     https://aice.study/main

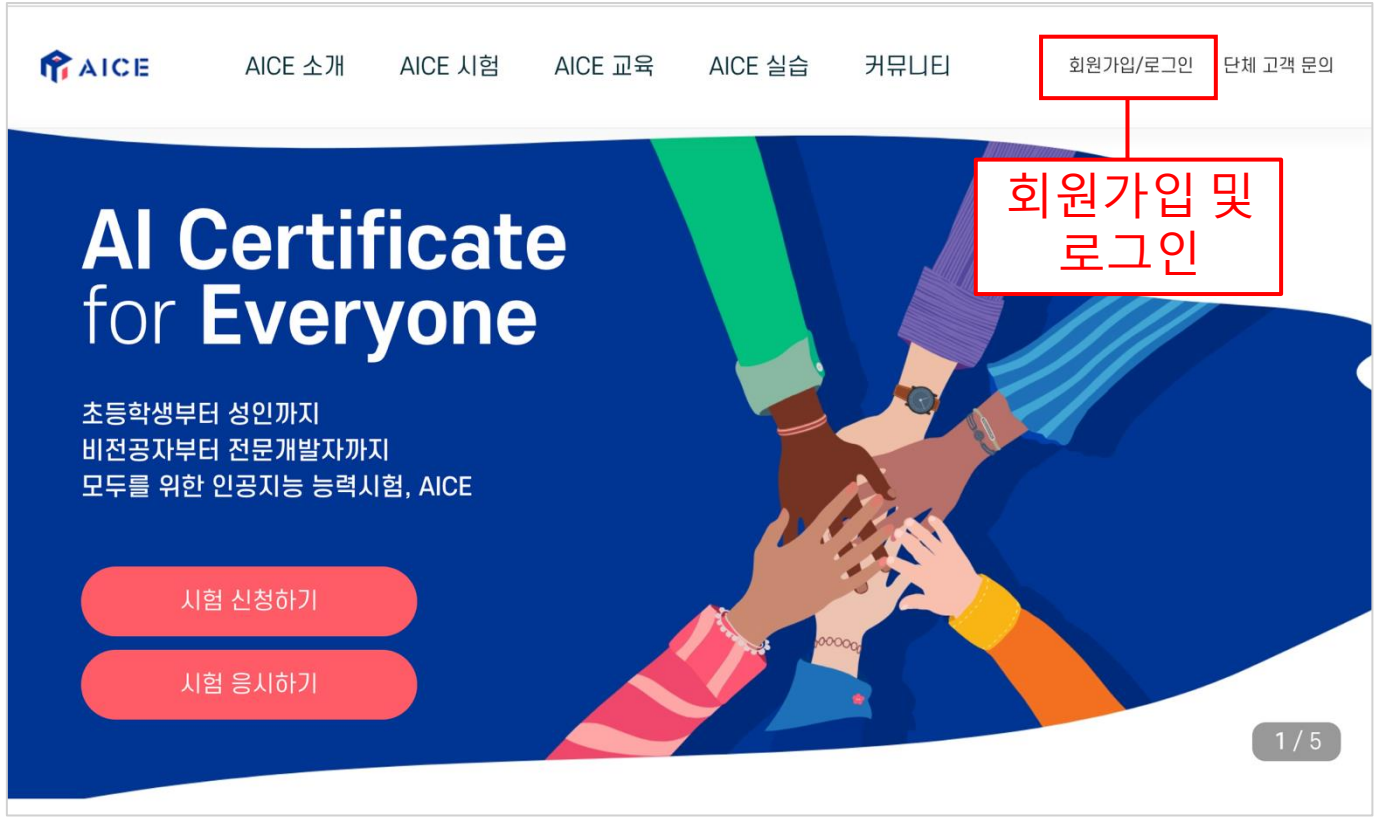

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

AICE 홈페이지의 AIDU 사용하기

AIDU : 설치가 필요 없는 웹 기반의 AI 모델링 환경과 용도 및 역량에 맞게 선택 가능한 AI 실습 툴

- **AIDU 실행하기**
  1. 아래 링크에 접속하여 우측 상단의 [회원가입] 후 로그인 (chrome으로 접속)
     https://aice.study/main
  2. AICE 실습 → 나의 프로젝트 클릭

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

AICE 홈페이지의 AIDU 사용하기

AIDU : 설치가 필요 없는 웹 기반의 AI 모델링 환경과 용도 및 역량에 맞게 선택 가능한 AI 실습 툴

- **AIDU 실행하기**
  1. 아래 링크에 접속하여 우측 상단의 [회원가입] 후 로그인 (chrome으로 접속)
     https://aice.study/main
  2. AICE 실습 → 나의 프로젝트 클릭
  3. Jupyter(주피터) 실행 가능

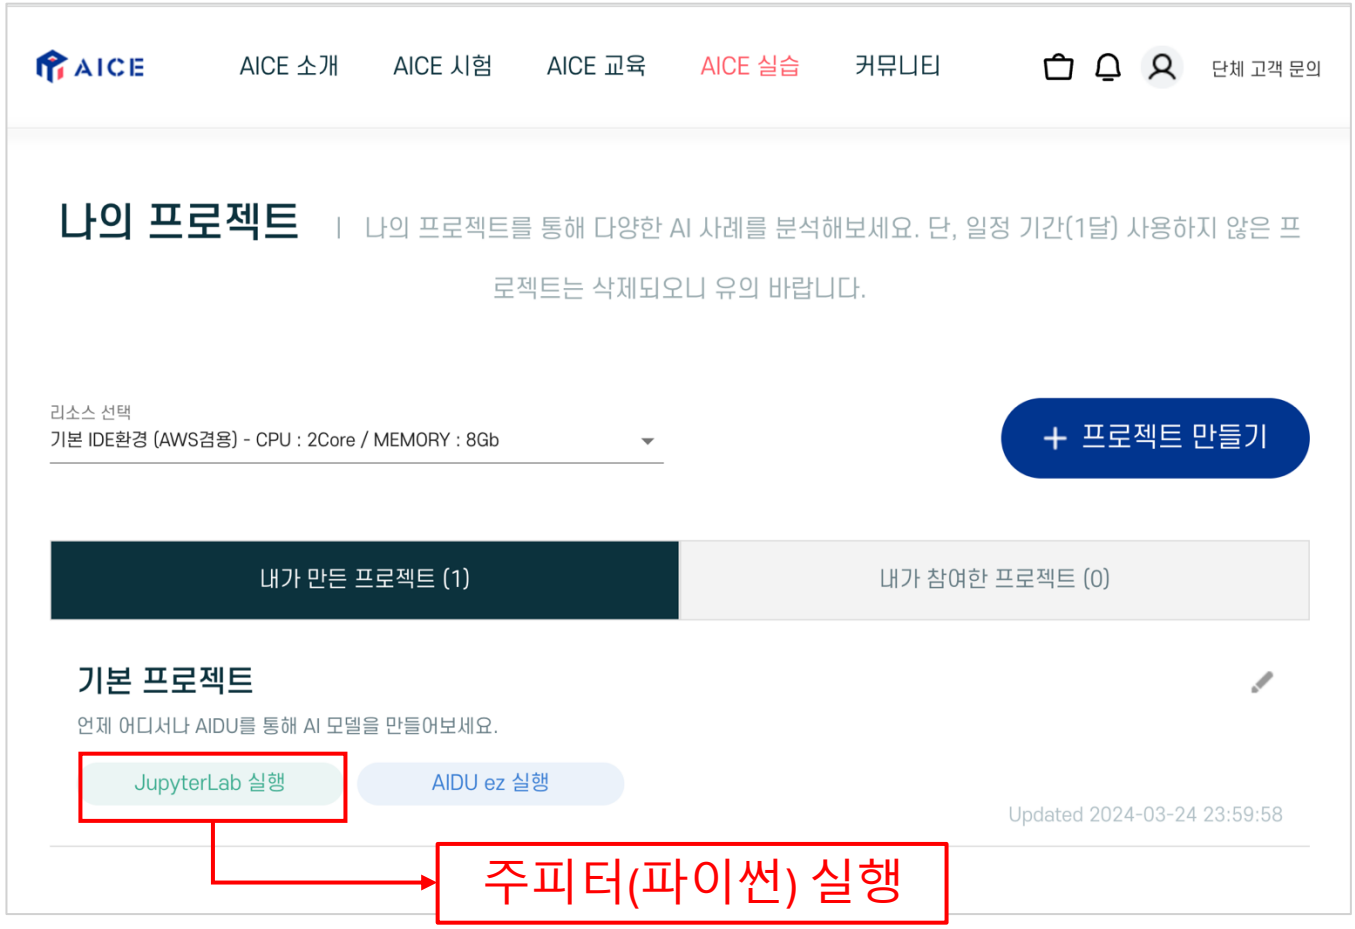

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

Python 데이터 분석 및 모델링

3) 데이터 분석 라이브러리 소개

수치형 데이터 처리, NumPy

❖ NumPy

1) **수치 데이터**를 다루는 데 활용
2) n차원 행렬 자료 구조인 np.array를 사용하여 배열이나 행렬 계산 등을 간편하고 빠르게 실행 가능 (np는 numpy의 별칭)
3) numpy 참고 도큐먼트 사이트 : https://numpy.org/doc/stable/reference/index.html
4) **넘파이(Numpy) 이용하기**

   넘파이를 사용하기 위해서는 넘파이 라이브러리를 가져와야 하며
   보통 아래와 같이 np라는 별칭으로 불러오기(import) 한다.

```
import numpy as np
```

ndarray : 넘파이를 통생 생성되는 n차원 배열(array) 객체
→ np.array는 리스트(List) 자료형과 비슷한 구조

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

수치형 데이터 처리, NumPy

- 넘파이(Numpy) 실습 코드

```
# 넘파이(Numpy) 라이브러리 불러오기
import numpy as np

# 넘파이(Numpy) 데이터 만들기
a = np.array([1,2,3,4,5])
b = np.array(['대한민국','포르투갈','가나','우루과이'])
c = np.array([1,2,'대한민국','포르투갈'])

print(a)
print(b)
print(c)
```

- 실행 결과

```
[1 2 3 4 5]
['대한민국' '포르투갈' '가나' '우루과이']
['1' '2' '대한민국' '포르투갈']
```

→ 실행 결과가 리스트 형태로 출력
→ 숫자형 데이터 [1,2,3,4,5]로 구성된 ndarray는 숫자로만 표기됨
→ 문자형 데이터로 구성된 ndarray는 문자열 형태로 보여줌
→ 숫자와 문자열을 혼합 사용하여 ndarray를 만들 경우 모든 내용을 문자열로 인식하여 출력

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

표 데이터 처리, Pandas

❖ Pandas

- 데이터 배열이나 테이블 형태의 데이터(tabular data) 등의 자료 구조를 처리하기 위한 라이브러리
- 시리즈(Series)와 데이터프레임(DataFrame) 자료구조를 주로 사용
  (pd는 pandas의 별칭)
  - **시리즈(Series)** : 1차원 데이터 배열
  - **데이터프레임(DataFrame)** : 행(Row)과 열(Column)로 구성된 2차원 데이터 테이블
- pandas 참고 도큐먼트 사이트 : https://pandas.pydata.org/pandas-docs/stable/

- **판다스(Pandas) 이용하기**
  판다스를 사용하기 위해서는 판다스 라이브러리를 가져와야 하며 보통 pd라는 별칭으로 선언

```
import pandas as pd
```

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

표 데이터 처리, Pandas

- 판다스(Pandas) 실습 코드 및 실행 결과
  - 시리즈(Series) 생성

    변수명 = pd.Series(data, index=index, name=name)

```python
# 판다스(Pandas) 라이브러리 불러오기
import pandas as pd

# 시리즈(Series) 생성하기
s = pd.Series(['대한민국', '포르투갈', '가나', '우루과이'], index=['가','나','다','라'], name='2022 카타르월드컵 H조')

# 출력하기
print(s)
```

✓ 0.0s

```
가     대한민국
나     포르투갈
다       가나
라     우루과이
Name: 2022 카타르월드컵 H조, dtype: object
```

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

표 데이터 처리, Pandas

- **판다스(Pandas) 실습 코드 및 실행 결과**
  - **데이터프레임(DataFrame) 생성** → 데이터프레임은 시리즈가 여러 개 합쳐진 자료형

    1. **딕셔너리(Dictionary) 형**으로 생성

```python
# 딕셔너리(Dictionary) 형으로 데이터프레임(DataFrame) 생성하기
a1 = pd.DataFrame({'a':[1,2,3],'b':[4,5,6],'c':[7,8,9]})
print(a1)
```

✓ 0.0s

```
   a  b  c
0  1  4  7
1  2  5  8
2  3  6  9
```

→ 열(column) 단위로 생성
→ 인덱스(index)와 열(column) 방식으로 생성

    2. **리스트(List) 형**으로 생성

```python
# 리스트(List)형으로 데이터프레임(DataFrame) 생성하기
a2 = pd.DataFrame([[1,2,3],[4,5,6],[7,8,9]], ['a','b','c'])
print(a2)
```

✓ 0.0s

```
   0  1  2
a  1  2  3
b  4  5  6
c  7  8  9
```

→ 행(row) 단위로 생성
→ a,b,c값이 인덱스로 설정

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

데이터 시각화(Visualization), Matplotlib

❖ Matplolib

1) **데이터 시각화**를 위한 기본적인 그래프 작성
2) 유연하고 다양한 그래프 스타일 제공
3) 그래프의 세부 조정이 용이
4) matplotlib 참고 도큐먼트 사이트 : https://matplotlib.org/stable/index.html
5) **matplotlib 이용하기**

   matplotlib로 그래프를 그리기 위해서는 matplotlib 안에 있는 pyplot 라이브러리를 가져와야 하며 보통 아래와 같이 plt라는 별칭으로 불러오기(import) 한다.

```
import matplotlib.pyplot as plt
```

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

데이터 시각화(Visualization), Seaborn

❖ Seaborn

1) **고급 통계 시각화**를 간단하게 아름답게 구현
2) 아름답고 스타일리시한 그래프 제공
3) pandas와 쉽게 연동
4) 통계적 데이터를 시각적으로 표현하는 데 강점
5) seaborn 참고 도큐먼트 사이트 : https://seaborn.pydata.org/
6) **seaborn 이용하기**

   seaborn으로 그래프를 그리기 위해서는 seaborn 라이브러리를 가져와야 하며
   보통 아래와 같이 sns라는 별칭으로 불러오기(import) 한다.

```
import seaborn as sns
```

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

Python 데이터 분석 및 모델링

4) 파이썬 AI 모델링 프로세스

파이썬 AI 모델링 프로세스

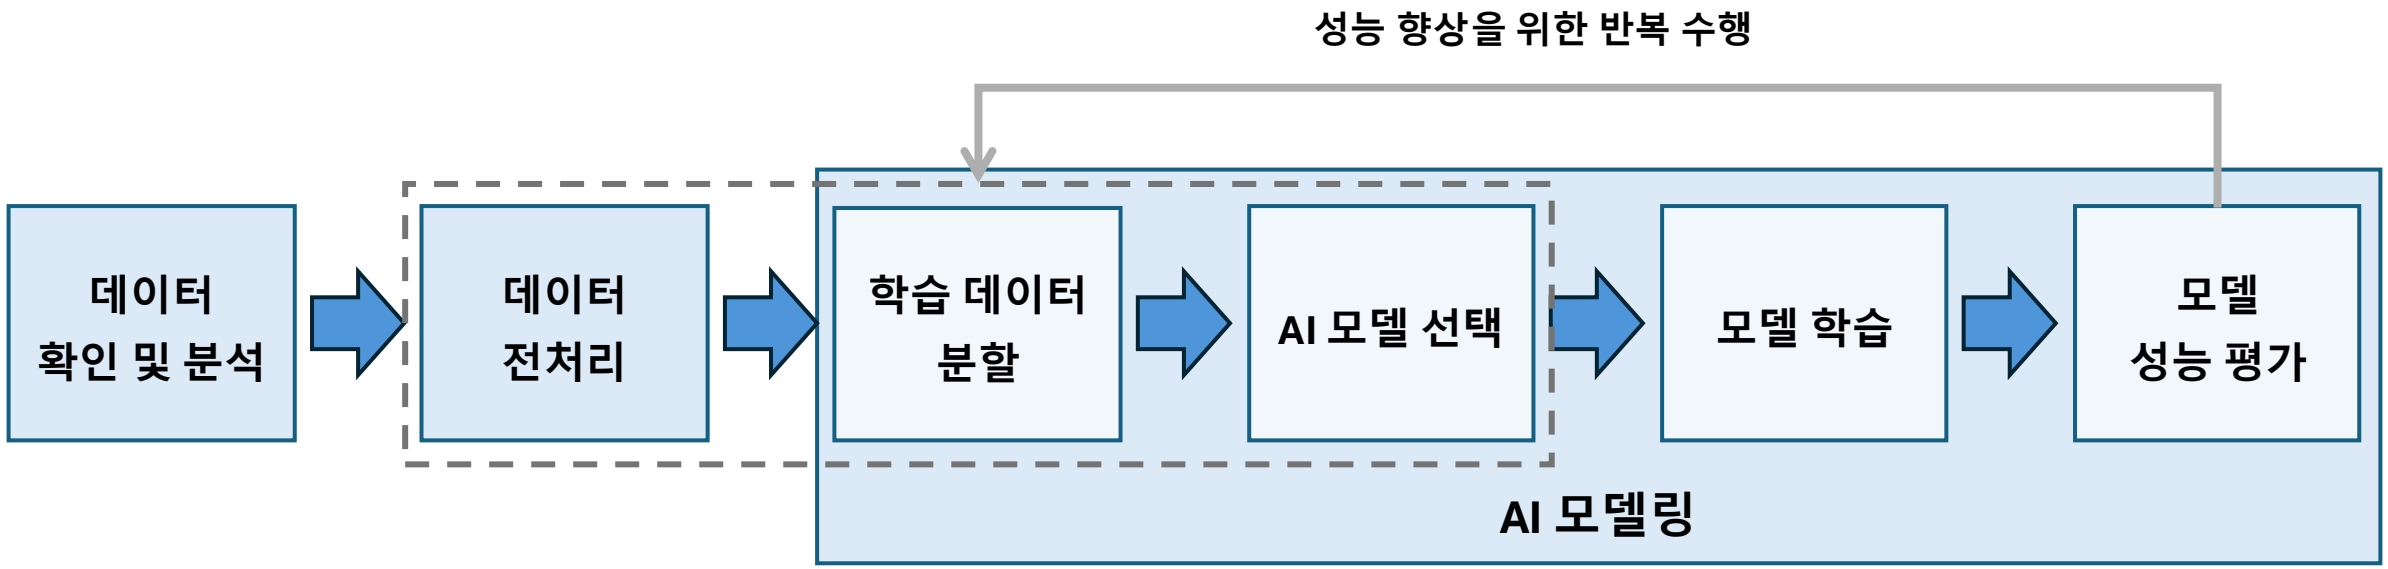

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

AI 모델링 프로세스

데이터 확인 및 분석

➢ **데이터 불러오기, 통계 확인 및 시각화**

- 데이터 유형 / 결측치 / 이상치 / 중복 / 분포 / 레이블링 여부 등 확인

데이터 전처리

➢ **데이터 전처리**

- 중복 데이터 제거, 결측치 처리, 학습에 불필요한 데이터 제거 등
- 새로운 데이터 생성, 인코딩 등

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

AI 모델링 프로세스

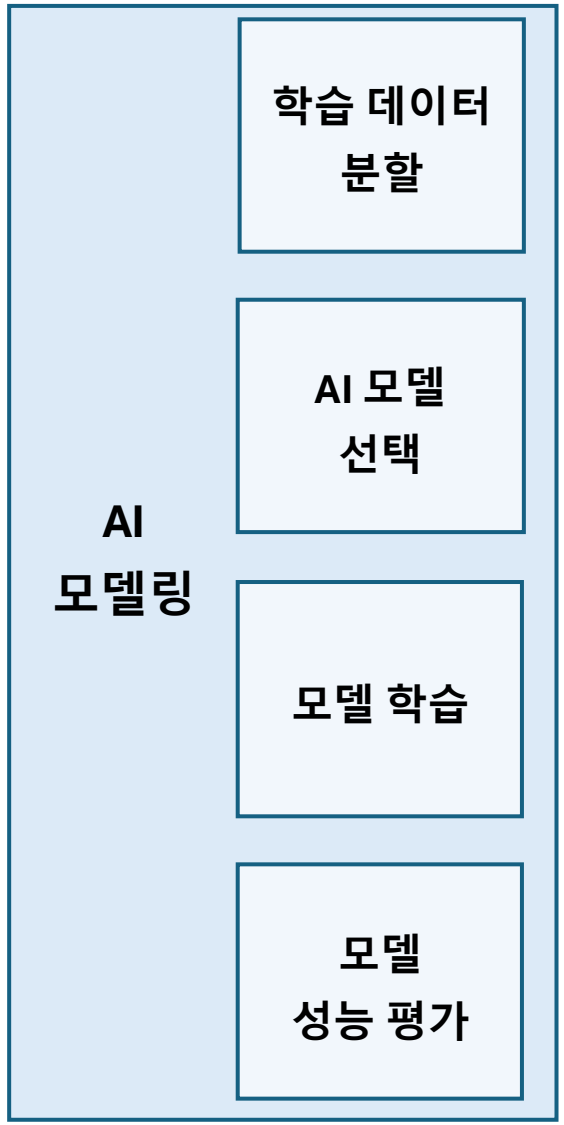

- **과적합 방지 및 성능평가를 위한 학습 데이터 분할**
  - 훈련(Train), 검증(Validation), 테스트(Test)로 분할
  - 비율은 보통 6:2:2 또는 7:2:1로 지정
- **적절한 수준의 AI 모델 선정**
  - 머신러닝? 딥러닝?
  - 회귀? 분류?
- **선택한 AI 모델을 학습**
  - 데이터를 입력(Input)하여 결과를 예측하도록 학습
- **학습 데이터와 검증 데이터로 학습 그래프 확인**
- **평가 데이터를 활용해 학습된 모델의 성능을 평가**
  - 성능이 좋지 않으면 데이터 전처리 추가 또는 AI 모델 변경, 각종 파라미터 변경

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

1) 데이터 확인 및 분석

- 기초 데이터 다루기

데이터 불러오기

- **데이터 불러오기**

  df = pd.read_csv('데이터 경로', encoding, …)

- **데이터 저장하기**

  df.to_csv('저장할 경로')

- **교차표(Crosstab) 확인**

  pd.crosstab(index=인덱스, columns=컬럼)

arrival_time	Afternoon	Early_Morning	Evening	Late_Night	Morning	Night
source_city						
Bangalore	6992	3154	14493	2673	10411	14338
Chennai	5152	1606	10830	1999	7106	12007
Delhi	8007	5262	14630	2143	13007	18294
Hyderabad	4816	1581	10539	2092	8854	12924
Kolkata	5941	2156	11304	2414	9595	14937
Mumbai	7231	1658	16527	2680	13762	19038

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

데이터 살펴보기

- **데이터 살펴보기**

```
df = pd.read_csv('../data/hotel_bookings.csv', encoding = "cp949")
```

- df.head(n)
- df.tail(n)

  → 각각 데이터프레임 내의 처음 n줄, 마지막 n줄의 데이터 출력 (n 지정 안할 시, 5개만 출력)

- df.shape
- df.columns
- df.info()
- df.dtypes

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

데이터 다루기 - 필요 데이터 선택

- **컬럼명으로 데이터 선택**

  df[‘컬럼명’] 또는 df[[‘컬럼명’]] → 원하는 컬럼의 데이터만 추출

  df[[‘컬럼명1’,‘컬럼명2’,‘컬럼명3’, …]] → 원하는 컬럼**들**의 데이터만 추출

- **행 범위를 지정해서 데이터 선택**

  df[시작 행 번호:끝 행 번호 + 1]

  df.loc[row_label, column_label] → 레이블 기반 인덱싱 사용하여 행과 열 선택

  df.iloc[row_index, column_index] →정수 기반 인덱싱 사용하여 행과 열 선택

- **조건으로 데이터 선택**

  df_extract = df[‘조건문’]

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

데이터 다루기 - 필요 데이터 변경

- **데이터 추가**

  df[‘새로운 컬럼명’] = ‘추가할 컬럼값’

  df.insert(삽입할 index, ‘새로운 컬럼명’, ‘추가할 컬럼값’)

- **데이터 삭제**

  df.drop(‘삭제할 컬럼명’, axis=1)

  df.drop(index=‘삭제할 인덱스값’, axis=0)

  → axis=1로 설정 시 컬럼 삭제, axis=0으로 설정 시 행 삭제

  → inplace=True로 설정하면 원본 데이터프레임을 변경!

- **컬럼명 변경**

  new_df = df.rename(columns={“컬럼명1":‘변경할 컬럼명1’, “컬럼명2":‘변경할 컬럼명2’,

  … })

- **데이터프레임 정렬**

  df = df.sort_values(by = ' 정렬 기준 열', ascending=False)

  → ascending이 True이면 오름차순, False이면 내림차순

데이터 다루기 – 데이터프레임 변경

- **그룹화**

  group_df = df.groupby(‘컬럼명’)

  → ‘컬럼명’을 기준으로 그룹화한 객체를 반환

  → 그룹화된 컬럼에 대해 다양한 통계 및 집계 확인/계산할 수 있음(실습 코드 참고)

- **피벗테이블 생성**

  df.pivot(index=‘컬럼명1', columns=‘컬럼명2', values =‘컬럼명3')

  - 데이터를 요약하고 요약/분석하는 데 사용되는 데이터 구조로 원본 데이터의 특정 열을 기준으로 데이터를 재구성하여 요약된 정보를 제공
  - 일반적으로 집계, 그룹화, 피벗(원본 데이터 형태를 변형하여 새로운 축을 생성)과 같은 작업을 수행할 때 사용
  - 복잡한 데이터를 간결하게 표현할 때 사용

- **인덱스 레이블 변경**

  new_df = df.set_index([‘컬럼명1’,’컬럼명2 '])

  → 지정한 컬럼을 인덱스로 변경

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

데이터 다루기 – 데이터프레임 변경

- **concat 활용하기1 (두 데이터프레임 컬럼명이 같은 경우)**

  pd.concat([df1, df2], ignore_index=True/False, axis = 0 또는 1)

  → 두 데이터프레임에 중복된 컬럼이 있는 경우 ignore_index를 True로 하면 합쳐진 데이터프레임의 인덱스가 처음부터 다시 계산되고, False로 하면 기존의 인덱스를 그대로 따름

  → axis를 0으로 설정 시 컬럼으로, 1로 설정 시 행으로 병합

- **concat 활용하기2 (두 데이터프레임 컬럼명이 다른 경우)**

  pd.concat([df1, df2], join='outer' 또는 'inner')

  → join을 'outer'로 설정 시, 두 데이터프레임의 모든 행을 포함하는 결과가 생성

  → join을 'inner'로 설정 시, 두 데이터프레임의 겹치는 인덱스 또는 컬럼에 대해서만 데이터를 결합

- **merge/join 활용하기**

  pd.merge(df1, df2, on='customer_id', how='left ')

  → on에 해당하는 컬럼을 기준으로 결합

  → how를 'outer'로 설정 시, 두 데이터프레임의 모든 on값을 포함하는 결과가 생성

  → how을 'inner'로 설정 시, 두 데이터프레임의 겹치는 on값에 대해서만 데이터를 결합

  → how을 'left'로 설정 시, 왼쪽 데이터프레임에 있는 on값에 대해서만 데이터를 결합

  → how을 'right'로 설정 시, 오른쪽 데이터프레임에 있는 on값에 대해서만 데이터를 결합

1) 데이터 확인 및 분석

- 데이터 분석

비시각화 분석

- **요약 통계량 및 빈도표 확인**
  - df.describe() : 컬럼별 요약 통계량 출력
    → 숫자형 데이터의 통계량(count:데이터 수, mean:평균값, std:표준편차, min:최솟값, max:최댓값, 4분위값)
    → 범주형 데이터의 통계량(데이터 수, 최빈값, 최빈값 개수)
  - df['컬럼명'].value_counts() : 지정된 컬럼의 값(value)의 발생 횟수 출력
- **상관계수 확인**
  - df.corr() : 데이터의 컬럼 간 상관관계 확인
    → +1 에 가까울수록 강한 양의 상관관계
    → -1 에 가까울수록 강한 음의 상관관계
    → 0에 가까울수록 상관관계가 없다.
  - df['컬럼명'].value_counts() : 지정된 컬럼의 값(value)의 발생 횟수 출력

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

데이터 시각화(Visualization), Matplotlib

➢ matplotlib 이용해 그래프 그리기

- matplotlib.pyplot을 plt로 선언하여 matplotlib를 불러온다(import).
- plt.bar(x,y) : 막대 그래프를 시각화
- plt.hist(data,bins=n) : 히스토그램을 시각화
  - bins 파라미터 : 계급을 몇 개의 구간으로 나눌지를 지정, 기본값 : 10
- plt.plot(x,y) : 선 그래프를 시각화
- plt.pie(data) : 파이 그래프를 시각화
- plt.boxplot(data) : 박스차트를 시각화
- plt.scatter(x,y) : 산점도를 시각화
- plt.pcolor(matrix) : 히트맵을 시각화
  - plt.colorbar() : 위 함수만 실행하면 히트맵만 그려지기 때문에 컬러바를 추가한다.

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

데이터 시각화(Visualization), Matplotlib

➢ matplotlib 관련 함수

- figure() : 그래프의 전체적인 객체(캔버스)를 생성하고 크기 및 해상도를 설정
- show() : 그래프의 객체를 화면에 보여줌

- title(str) : 그래프의 제목을 설정
- xlabel(str) / ylabel(str) : x, y축 제목(레이블)을 설정
- xlim([min,max]) / ylim([min,max]) : x, y축의 표시 범위 지정
- xticks() / yticks() : x, y축의 눈금 값과 크기, 기울기 등 설정
- grid(True/False) : 그래프에 격자를 표기할 것인지 지정
- legend() : 그래프에 범례 추가

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

데이터 시각화(Visualization), Seaborn

➢ **seaborn 관련 함수**

- set_theme() : 그래프의 전체적인 객체(캔버스)를 생성하고 크기 및 해상도를 설정
- set_style(style='whitegrid) : 그래프의 배경 및 격자 스타일을 지정
- set_palette() : 그래프의 색상 팔레트를 설정

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

데이터 시각화(Visualization), Seaborn

➢ seaborn 이용해 그래프 그리기

- seaborn을 sns로 선언하여 seaborn을 불러온다(import).
- sns.barplot(x,y,data) : 막대그래프 생성
- sns.countplot(data) : 카운트플롯 생성
- sns.histplot(data,bins=n) : 히스토그램 생성
- sns.lineplot(x,y,data) : 선그래프 시각화
- sns.boxplot(x,y,data) : 박스차트 생성
- sns.scatterplot(x,y,data) :산점도 생성
- sns.catplot() : 범주형 변수의 산점도를 시각화
- sns.jointplot(x,y,data) : 수치형 변수의 산점도와 히스토그램을 시각화
- sns.pairplot() :여러 변수 간 산점도 생성

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

2) 데이터 전처리

- 데이터 전처리하기

1) 결측치 처리

- **결측치**
  - 파이썬에서는 결측치를 'NaN'으로 표기
- **결측치 확인**
  - info() 메서드를 사용하면 인덱스의 범위(RangeIndex), 컬럼별 non-null 수를 확인할 수 있는데, RangeIndex정보의 entries수와 컬럼 정보의 컬럼별 non-null 수를 비교해보면 결측치의 존재 여부를 확인 가능

전체 entries 수

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 300153 entries, 0 to 300152
Data columns (total 11 columns):
 #   Column            Non-Null Count   Dtype
---  ------            --------------   -----
 0   airline           299685 non-null  object
 1   flight            299689 non-null  object
 2   source_city       299681 non-null  object
 3   departure_time    299723 non-null  object
 4   stops             299666 non-null  object
 5   arrival_time      299698 non-null  object
 6   destination_city  299670 non-null  object
 7   class             299715 non-null  object
 8   duration          299703 non-null  float64
 9   days_left         299723 non-null  float64
 10  price             299714 non-null  float64
dtypes: float64(3), object(8)
memory usage: 25.2+ MB
```

(전체 entries 수) – (non-null 개수) = (null 개수)

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

1) 결측치 처리

- **결측치 수 확인**
  - isnull() : 값이 null이면 True, null이 아니면 False를 반환
  - isnull().sum(axis=0) : 데이터프레임 컬럼 기준(axis=0)으로 합(sum)하면 True의 합, 즉 결측치의 개수를 반환
- **결측치 처리**
  - dropna() : 행 기준으로 각 컬럼값에 결측값에 1개라도 있으면 해당 행 삭제
    - how파라미터를 'all'로 설정하면 모든 컬럼이 결측치인 행만 삭제됨
  - drop(['컬럼명']) : 지정한 컬럼 삭제
  - fillna() : 파라미터에 지정하는 값으로 결측치를 대체
    - 파라미터 : (데이터프레임).mean(), (데이터프레임).min(), ...

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

2) 이상치 처리

- **IQR 계산하기**
  - quantile() : 데이터를 크기별로 줄 세운 후 해당하는 퍼센트에 따른 값으로 반환
    - quantile(0.25) → 제1사분위수, quantile(0.75) → 제3사분위수

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

3) 스케일링 (수치형 변수)

- **정규화 스케일링**

```
from sklearn.preprocessing import MinMaxScaler
scaler = MinMaxScaler()
scaler.fit_transform(x_train)
scaler.transform(x_valid)
```

- **표준화 스케일링**

```
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
scaler.fit_transform(x_train)
scaler.transform(x_valid)
```

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

4) 인코딩 (범주형 변수)

- **레이블 인코딩**
  - from sklearn.preprocessing import LabelEncoder

    LabelEncoder = LabelEncoder()

    LabelEncoder.fit_transform(x_train)

    LabelEncoder.transform(x_valid)
  - LabelEncoder.inverse_transform() : 디코딩도 가능
- **원-핫 인코딩**
  - **pandas 활용**
    - get_dummies() : 바로 원-핫 인코딩 가능
  - **사이킷런(scikit-learn) 활용**
  - from sklearn.preprocessing import OneHotEncoder

    OneHotEncoder = OneHotEncoder()

    OneHotEncoder.fit_transform(x_train)

    OneHotEncoder.transform(x_valid)

3) AI 모델링

- 학습 데이터 분할

scikit-learn을 이용한 학습 데이터 분할

➢ **train_test_split 함수**

- 사용자가 전체 데이터를 직접 나누면 번거롭고, 학습에 적합하도록 분배하기도 어려움

→ scikit-learn의 train_test_split 함수를 활용하면 쉽게 데이터 분할 가능

```
from sklearn.model_selection import train_test_split
x_train, x_valid, y_train, y_valid = train_test_split(data, target, test_size=None,
        train_size=None, random_state=None, shuffle=True, stratify=None)
```

x : 예측에 쓰일 입력값(Input)

y : 맞춰야 하는 정답값(레이블)

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

scikit-learn을 이용한 학습 데이터 분할

➢ **train_test_split 함수**

- 사용자가 전체 데이터를 직접 나누면 번거롭고, 학습에 적합하도록 분배하기도 어려움

→ scikit-learn의 train_test_split 함수를 활용하면 쉽게 데이터 분할 가능

```
from sklearn.model_selection import train_test_split
x_train, x_valid, y_train, y_valid = train_test_split(data, target, test_size=None,
        train_size=None, random_state=None, shuffle=True, stratify=None)
```

test_size : 전체 데이터 중 test 데이터의 비율

train_size : 전체 데이터 중 train 데이터의 비율

random_state : 데이터 분할 전 데이터에 적용되는 셔플링을 제어

shuffle : 데이터 분할 전 데이터를 섞을지 여부를 결정

stratify : 데이터 분할에서 자동으로 Target의 데이터 분포 비율을 유지할지 결정

3) AI 모델링

- 머신러닝 모델링

scikit-learn 라이브러리

- **scikit-learn 라이브러리**

  파이썬에서 머신러닝을 구현하기 위해 널리 사용되는 라이브러리로, 분류/회귀/군집화 등의 다양한 머신러닝 알고리즘을 쉽게 사용할 수 있는 도구 제공

  ❖ **다양한 머신러닝 알고리즘 제공**

  - **분류(Classification)** : SVM, k-Nearest Neighbors, Decision Tree, Random Forest, Logistic Regression 등
  - **회귀(Regression)** : 선형회귀(Linear Regression), Lasso, Ridge 등
  - **군집화(Clustering)** : K-Means, DBSCAN, 계층적 군집화
  - **차원 축소(Dimensionality Reduction)** : PCA, t-SNE
  - **모델 평가 및 선택** : 교차 검증(Cross-validation), 하이퍼파라미터 튜닝(GridSearchCV, RandomizedSearchCV)

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

머신러닝 모델링

- **scikit-learn 라이브러리 활용**

  분류/회귀/클러스터링/차원축소 등의 머신러닝 모델들을 간단하고 효율적으로 구현 가능

  1. **데이터 준비** : 입력 데이터(X)와 타겟 변수(y) 준비
  2. **모델 선택** : sklearn에서 제공하는 다양한 알고리즘 중 선택
  3. **모델 학습** : fit() 메서드를 사용하여 모델 학습
  4. **모델 평가** : 테스트 데이터에 모델을 적용하고 성능 평가
  5. **예측** : 학습된 모델을 사용해 새로운 데이터에 대한 예측 수행

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

머신러닝 모델링

- **scikit-learn 라이브러리 활용**

[예시1 : 선형회귀]

```
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression

# 데이터 준비
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2)

# 모델 선택 및 학습
model = LinearRegression()
model.fit(X_train, y_train)

# 모델 평가
accuracy = model.score(X_test, y_test)
print("Accuracy:", accuracy)

# 새로운 데이터에 대한 예측
new_data = [[...], [...], ...]
predictions = model.predict(new_data)
```

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

머신러닝 모델링

- **scikit-learn 라이브러리 활용**

[예시2 : 랜덤 포레스트]

```
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier

# 데이터 준비
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2)

# 모델 선택 및 학습
model = RandomForestClassifier()
model.fit(X_train, y_train)

# 모델 평가
accuracy = model.score(X_test, y_test)
print("Accuracy:", accuracy)

# 새로운 데이터에 대한 예측
new_data = [[...], [...], ...]
predictions = model.predict(new_data)
```

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

3) AI 모델링

- 딥러닝 모델링

keras를 활용하여 딥러닝 구현하기

- **keras 소개**

  딥러닝 모델을 쉽게 구축하고 학습시키기 위한 파이썬의 고수준 딥러닝 API

- **딥러닝 모델 구축 단계**

  1. 모델 정의 : Sequential 모델 또는 함수형 API를 사용해 모델 구조를 정의
  2. 모델 컴파일 : 모델의 손실 함수, 최적화 알고리즘, 평가 지표 등을 지정하여 모델을 컴파일
  3. 모델 학습 : 훈련 데이터를 사용해 모델을 학습
  4. 모델 평가 : 테스트 데이터를 사용해 모델의 성능을 평가

- **keras 주요 기능**

  다양한 레이어(Layer) 제공 : Dense, Convolutional, Recurrent 등 다양한 레이어 지원

  손실 함수 및 최적화 알고리즘 제공 : 다양한 손실 함수와 최적화 알고리즘을 제공하여 선택할 수 있음

  내장 데이터셋 및 데이터 전처리 기능 : 내장된 데이터셋을 제공하고 데이터 전처리를 위한 유틸리티 함수를 제공하여 데이터 준비 과정을 간편화할 수 있음

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

keras를 활용하여 딥러닝 구현하기

- **keras 활용하여 딥러닝 구현**

[예제]

```
from keras.models import Sequential
from keras.layers import Dense

# 모델 정의
model = Sequential([
Dense(units=64, activation='relu', input_shape=(784,)),
Dense(units=64, activation='relu'),
Dense(units=10, activation='softmax')
])

# 모델 컴파일
model.compile(optimizer='adam',
loss=' mse',
metrics=['accuracy'])

# 모델 학습
model.fit(x_train, y_train, epochs=10, validation_data=(x_val, y_val))

# 모델 평가
test_loss, test_acc = model.evaluate(x_test, y_test)
```

3) AI 모델링

- 모델 평가

Scikit-learn.metrics 활용한 모델 평가

- **scikit-learn 라이브러리 활용**

[예시3 : 다양한 평가지표를 활용해 모델 평가하기]

```
# 분류모델을 위한 평가지표
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score

accuracy = accuracy_score(y_test, y_pred)

precision = precision_score(y_test, y_pred)

recall = recall_score(y_test, y_pred)

f1 = f1_score(y_test, y_pred)

# 회귀모델을 위한 평가지표
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score

mae = maen_absolute_error(y_test, y_pred)

mse = mean_squared_error(y_test, y_pred, squared=True)

rmse = mean_squared_error(y_test, y_pred, squared=False)

r2 = r2_score(y_test, y_pred)
```

본 자료는 더에이아이랩(조우연)이 제작하였으며, 저작권 보호를 받습니다. 무단 복제/배포를 금합니다.

AI Certificate for Everyone

더에이아이랩(주)
AICE공인교육기관